

Proyecto #1: Sistema Inteligente Adaptativo para la Predicción de Reingreso Hospitalario en Pacientes Diabéticos

Curso: Planificación y Toma de Decisiones en IA (UTEC 2026-I)

Profesores: Dra. Aurea Soriano-Vargas & Mg. Robert Buleje

Dataset Seleccionado: Diabetes 130-US hospitals for years 1999-2008 (UCI Machine Learning Repository)

Etapas: Entrega 1 - Avance de Diseño del Sistema, Objetivos, Restricciones y Plan de Monitoreo

1. Descripción del Problema y Caso de Uso.....	2
1.1. Descripción del Problema.....	2
2. Definición de Objetivos.....	3
2.1. Objetivo General.....	3
2.2. Objetivos Específicos.....	3
3. Definición de Restricciones.....	3
4. Métricas de Éxito.....	4
5. Diseño del Sistema de IA y Arquitectura.....	7
5.1. Esquema de la Arquitectura del Sistema.....	9
6. Mini Plan de Trabajo para el Proyecto.....	9
6.1. Modelos Mapeados para Comparación.....	9
6.2. Estrategia de Monitoreo de Data/Concept Drift mediante Ventanas Fijas.....	10
6.3. Cronograma de Actividades (Roadmap).....	11
8. Bibliografía.....	12

1. Descripción del Problema y Caso de Uso

1.1. Descripción del Problema

Cuando un paciente con diabetes sale del hospital, existe la posibilidad de que tenga que volver antes de 30 días. A esto se le llama reingreso hospitalario no planificado, y es un problema serio para cualquier sistema de salud. Afecta la calidad de vida del paciente. Satura los servicios de emergencia. Y le cuesta caro a las instituciones: en Estados Unidos existen programas como el Hospital Readmissions Reduction Program (HRRP), que multan a los hospitales con demasiados reingresos. Aunque con frecuencia se asume que la causa reside únicamente en la fragilidad biológica del enfermo, estudios muestran que entre un 20% y un 27% de estos reingresos son potencialmente evitables (van Walraven, C., et al., 2011), vinculados a tratamientos intrahospitalarios subóptimos, fallas en la conciliación de medicamentos y deficiencias de comunicación durante el alta. Anticipar el riesgo permite no solo vigilar al paciente vulnerable, sino también corregir oportunamente estas brechas en la atención clínica.

Este proyecto trabaja con datos históricos de más de 100,000 hospitalizaciones de pacientes diabéticos, registradas en 130 hospitales de Estados Unidos entre 1999 y 2008. Una década es mucho tiempo en medicina: la forma de tratar la diabetes cambió, la manera de registrar los diagnósticos cambió, y los medicamentos que se recetan (metformina, insulina) también. Un patrón que servía para predecir el riesgo de un paciente en 1999 puede no servir diez años después.

Por eso, el objetivo no es solo predecir el riesgo de reingreso en el momento del alta. Es también detectar cuándo esas predicciones dejan de ser confiables por los cambios en el tiempo, y corregirlas antes de que eso afecte a un paciente real.

Pensemos en un caso concreto. Un paciente diabético lleva varios días internado, le ajustaron el tratamiento de insulina, y ya tuvo hospitalizaciones anteriores. Está por recibir el alta. En ese momento, el sistema calcula qué tan probable es que vuelva al hospital en los próximos 30 días y lo traduce en una categoría simple: riesgo Bajo, Moderado o Alto. Muestra al médico qué factores pesaron más en esa predicción y sugiere un plan de seguimiento según el nivel de riesgo. Si el riesgo es alto, por ejemplo, sugiere una cita presencial prioritaria y una revisión urgente de los medicamentos.

El médico es quien decide. El sistema nunca da de alta ni cambia un tratamiento por su cuenta; solo recomienda, y el personal médico acepta, ajusta o descarta esa recomendación. Y de fondo, el sistema se revisa a sí mismo cada cierto tiempo: si sus predicciones empiezan a fallar más de lo esperado, porque los patrones clínicos cambiaron, se dispara un proceso para actualizarlo con datos más recientes, de modo que siga siendo útil con el paso de los años.

2. Definición de Objetivos

2.1. Objetivo General

Implementar un sistema predictivo adaptativo que clasifique con alta confiabilidad el riesgo de

reingreso hospitalario a 30 días en pacientes diabéticos, con el fin de tomar acción y reducir esta cantidad. El sistema debe mantener un rendimiento estable a lo largo del tiempo mediante monitoreo periódico y estrategias de reentrenamiento con ventanas fijas ante la presencia de drift.

2.2. Objetivos Específicos

- **Diseñar e implementar el flujo de ingesta y preprocesamiento de datos** del historial de atención, preservando la secuencialidad estricta de las admisiones para evitar la fuga de información durante el proceso de validación e inferencia.
- **Construir y comparar modelos de clasificación supervisada** para predecir el riesgo de reingreso hospitalario a 30 días, evaluando su capacidad discriminativa inicial sobre los registros secuenciales.
- **Desarrollar un componente de calibración de probabilidades y estimación de incertidumbre** que evalúe el nivel de confianza de cada pronóstico antes de generar alertas al personal de salud.
- **Diseñar un motor de decisión basado en matrices de utilidad y costos ponderados** del error que categorice el nivel de riesgo y adapte dinámicamente sus umbrales según el contexto operativo del hospital.
- **Establecer protocolos de acción clínica de soporte** e implementar un esquema de monitoreo por **ventanas fijas** secuenciales para detectar la degradación del modelo y activar estrategias de reentrenamiento ante la presencia de concept drift.

3. Definición de Restricciones

El diseño del sistema responde a limitaciones operacionales, computacionales, éticas y de datos descritas a continuación:

Categoría de Restricción	Descripción de la Limitación	Impacto en el Sistema de IA
Secuencialidad Temporal	No se permite mezclar aleatoriamente el dataset (K-Fold cross-validation convencional está prohibido).	La validación debe ser strictly time-series split o rolling window para evitar fuga de información del futuro.
Autonomía y Decisión Clínica	El sistema no puede modificar prescripciones médicas ni emitir bajas o altas médicas de forma 100% autónoma.	Opera bajo esquema Human-in-the-Loop (HITL), recomendando planes de seguimiento al médico tratante.
Privacidad y Normativa (HIPAA, Regla HTI-1 de la	HIPAA: Manejo de datos sensibles de salud	El pipeline productivo debe replicar los controles de

Categoría de Restricción	Descripción de la Limitación	Impacto en el Sistema de IA
ONC)	protegidos por normativas de privacidad. ONC: transparencia para la inteligencia artificial (IA) en software médico.	anonimización ya aplicados en el dataset UCI (eliminación de identificadores directos, agregación de fechas) antes de que cualquier dato ingrese al módulo predictivo, dado que un despliegue real dentro del EHR manejaría datos identificables previos a la desidentificación, sujetos a HIPAA

4. Métricas de Éxito

Para evaluar el desempeño holístico del sistema adaptativo, se establecen tres dimensiones de métricas:

Dimensión	Métrica	Criterio de Aprobación	Justificación	Literatura
Técnicas	ROC-AUC	≥ 0.66 (en validación temporal out-of-time)	Evalúa la capacidad general del modelo para discriminar entre pacientes que reingresan y los que no, independiente del umbral elegido.	Investigaciones recientes con este mismo <i>dataset</i> reportan un techo de 0.667 con XGBoost y 0.642 con Regresión Logística (Emi-Johnson & Nkrumah, 2025). Kansagara et al. (2011) demostraron que los modelos basados en datos administrativos raramente superan el 0.65-0.70.
	PR-AUC (AUPRC)	≥ 0.20 <i>(con un lift ≥ 1.8 x sobre prevalencia)</i>	Es superior al ROC-AUC para evaluar el desempeño en datasets altamente desbalanceados (Saito & Rehmsmeier, 2015), ya que se enfoca en el rendimiento sobre la clase minoritaria (reingreso).	La línea base ("no-skill") equivale a la prevalencia de la clase positiva (11.2% o 0.112). En este <i>dataset</i> , el PR-AUC real esperado es de aprox. 0.21.
	Calibration Slope & Intercept	Slope: [0.85, 1.15] Intercept: [-0.15, 0.15]	Es el "talón de Aquiles" clínico (Van Calster et al., 2019). Asegura que las probabilidades (ej. "30% de riesgo") correspondan a la tasa empírica real de reingreso, evitando sobreestimar o subestimar el riesgo.	Un <i>slope</i> <1 indica sobre-extremidad por <i>overfitting</i> , y un <i>intercept</i> lejano a 0 refleja sesgo sistemático. El rango propuesto garantiza que el modelo sea confiable para acoplarse al motor de costos y decisiones clínicas sin generar alarmas falsas.
De Decisión	Beneficio Neto (Decision Curve)	Superar las políticas base ("tratar a todos" o "no tratar	Es el estándar de oro (criterio primario) para justificar la	Vickers & Elkin (2006) establecen que el DCA es necesario para validar si las

Dimensión	Métrica	Criterio de Aprobación	Justificación	Literatura
	Analysis - DCA)	a nadie") en el rango de umbrales clínicos plausibles (aprox. 9% – 20%).	implementación clínica. Un modelo puede tener buena precisión matemática, pero si no genera más beneficio que las políticas por defecto, no debe usarse.	intervenciones guiadas por el modelo aportan valor real. Reemplaza la meta arbitraria e irreal de reducir los reingresos absolutos en un 15-20%
	Costo Esperado Ponderado (Matriz de Costo)	Minimizar costo $C = 10 \times FN + 1 \times FP$. <i>(Realizar análisis de sensibilidad entre 5:1 y 27:1)</i>	Traduce los errores del modelo a impacto económico y de salud. Penaliza severamente los falsos negativos (FN), ya que dejar ir a un paciente que luego reingresa grave es mucho peor que monitorear a alguien sano (FP).	Ghabowen et al. (2024) estiman el costo de un reingreso en aprox. US\$16,000 frente a intervenciones de aprox US\$500-600 (ratio crudo aprox 27:1). Esto valida que la razón propuesta en el diseño original de penalizar un FN 10 veces más que un FP es correcta, sólida y conservadora.
	Tasa de Alertas (Alert Burden / Tasa de Selección)	Fijar la tasa de pacientes alertados para intervención a un número < a la capacidad real de seguimiento del hospital.	Las enfermeras y médicos tienen tiempo y recursos limitados. Si el sistema emite demasiadas alertas de "Alto Riesgo", generará "fatiga de alertas" y el personal comenzará a ignorar el algoritmo.	La literatura empírica reporta tasas de rechazo (<i>override</i>) de alertas de hasta 90% en sistemas clínicos (van der Sijs et al., 2006; Ancker et al., 2017). Controlar esta tasa asegura que la herramienta se adapte a las verdaderas restricciones operativas del hospital..
Sociales Éticas /	Igualdad de Oportunidad (Equalized Odds)	Ratio de la Tasa de Falsos Negativos (FNR) entre grupos en el rango [0.87, 1.15] , validado solo en subgrupos con tamaño	Garantiza que el modelo no cometa más errores graves (dejar ir a alguien que va a reingresar) en grupos vulnerables (ej. mayores de 70	Hardt, Price & Srebro (2016) demostraron que medir el ratio de FNR es la forma correcta de auditar esto. Exigir paridad estricta dañaría el modelo porque la prevalencia de la

Dimensión	Métrica	Criterio de Aprobación	Justificación	Literatura
		mayor o igual a 100.	años o minorías raciales) frente al grupo mayoritario.	diabetes naturalmente varía por edad.
	Disparate Impact (Regla del 80%)	Ratio de la tasa de selección (porcentaje de pacientes marcados con alerta preventiva) entre grupos ≥ 0.80 .	Asegura equidad en el acceso a los recursos del hospital. Verifica que el sistema no esté excluyendo sistemáticamente a un grupo demográfico de recibir atención preventiva prioritaria.	Es el estándar legal basado en la regla de los 4/5 de la EEOC en EE. UU. A diferencia del error común, esta métrica se aplica sobre quién recibe la "alerta", no sobre la tasa de error del modelo.
	Calibración por Subgrupo	Curva de calibración (<i>slope</i> & <i>intercept</i>) aceptable dentro de cada grupo (edad, raza).	Un modelo puede parecer perfecto a nivel global, pero estar subestimando el riesgo específicamente en pacientes de una raza minoritaria, lo cual es clínicamente inaceptable.	Van Calster et al. (2019) y Chouldechova (2017) señalan que auditar la calibración dentro de cada subgrupo es crítico. Es imposible satisfacer equidad y calibración perfectamente al mismo tiempo si las tasas base difieren, por lo que monitorear ambas expone los verdaderos sesgos del sistema.

5. Diseño del Sistema de IA y Arquitectura

El sistema está diseñado para operar como una herramienta de soporte integrada dentro del flujo de trabajo clínico existente, no como una aplicación independiente. El **usuario principal es el médico tratante** o el equipo de enfermería responsable del alta, quienes interactúan con el sistema en el momento exacto en que completan el proceso de alta médica dentro del sistema EHR. Al finalizar la evaluación clínica del paciente, el módulo predictivo se activa automáticamente y despliega el nivel de riesgo estimado (junto con las variables explicativas principales) directamente en la pantalla de "Resumen de Alta", sin requerir una solicitud manual por parte del personal médico. **El sistema sugiere un protocolo de seguimiento según el riesgo calculado**, pero es el médico quien aprueba, modifica o descarta la recomendación, en línea con el esquema Human-in-the-Loop definido en las restricciones.

El sistema se concibe como un pipeline continuo adaptativo compuesto por 5 módulos principales interconectados:

1. Módulo de Adquisición e Integración de Datos:

- Ingesta continua de registros clínicos de alta desde el sistema de Historia Clínica Electrónica (EHR).
- Integración de datos demográficos (`age`, `race`), clínicos (`time\_in\_hospital`, `num\_lab\_procedures`, `num\_medications`, `number\_inpatient`), diagnósticos principales (`diag\_1`, `diag\_2`, `diag\_3`) y esquemas de medicación (`metformin`, `insulin`, `change`).

2. Módulo Predictivo Adaptativo:

- Ejecución del preprocesamiento y transformación de variables en tiempo real.
- Inferencia mediante el modelo supervisado activo para calcular la probabilidad ajustada de reingreso dentro de los 30 días.

3. Módulo de Manejo de Incertidumbre:

- Calibración de probabilidades mediante Platt Scaling / Isotonic Regression.
- Cálculo de intervalos de confianza del pronóstico. Si la incertidumbre es superior al umbral definido ($\sigma > 0.35$), la predicción se marca como "Incertidumbre Alta" para revisión médica obligatoria.

4. Módulo de Toma de Decisiones y Clasificación de Riesgo:

- Matriz de Utilidad que asigna la categoría de riesgo: *Bajo Riesgo*, *Riesgo Moderado* o *Alto Riesgo*.
- Ajuste dinámico del umbral de decisión en función de la capacidad asistencial y la penalización económica por reingreso.
- El umbral se recalibra en cada ventana fija de monitoreo (ver Sección 6.2): si la ocupación hospitalaria proyectada supera el 85% de capacidad, el umbral de "Alto Riesgo" se reduce en 0.05 puntos de probabilidad para priorizar casos con menor margen de error, restableciéndose al valor base cuando la ocupación vuelve a niveles normales.

5. Componente de Acción e Intervención:

- **Bajo Riesgo:** Alta médica con protocolo estándar de seguimiento ambulatorio.
- **Riesgo Moderado:** Generación de alerta en EHR para llamada de control a los 7 días y entrega de kit educativo para diabetes.

- **Alto Riesgo:** Alerta prioritaria para agendar cita médica presencial dentro de los 7 días posteriores al alta, conciliación farmacológica urgente y asignación de un gestor de caso.

5.1. Esquema de la Arquitectura del Sistema




Figura 1. Arquitectura del sistema (6 módulos): Adquisición desde EHR → Preprocesamiento de Features → Modelo Predictivo Adaptativo → Evaluador de Incertidumbre y Calibración → Módulo de Decisión con Umbrales → Componente de Acción Clínica, con retroalimentación del Módulo de Monitoreo de Drift hacia el reentrenamiento del modelo.

6. Mini Plan de Trabajo para el Proyecto

6.1. Modelos Mapeados para Comparación

Acorde a los requerimientos del curso, se han seleccionado 3 enfoques de modelado representativos:

- **Modelo Tradicional 1 - Regresión Logística Regulada (ElasticNet):** Sirve como baseline interpretable de baja complejidad lineal. Facilita la medición rápida del impacto de cada variable clínica y la comparación contra modelos más complejos.
- **Modelo Tradicional 2 - LightGBM con Atributos Temporales / TabNet:** Modelo de Gradient Boosting altamente optimizado para datos tabulares de gran escala con soporte eficiente para codificación ordinal temporal y ponderación de clases desbalanceadas.
- **Modelo Avanzado - Random Forest / XGBoost:** Algoritmo basado en árboles de decisión ensamblados para capturar interacciones no lineales entre diagnósticos, cantidad de medicamentos y permanencia hospitalaria.

6.2. Estrategia de Monitoreo de Data/Concept Drift mediante Ventanas Fijas

En esta etapa inicial se emplea una **estrategia de evaluación periódica por ventanas fijas deslizantes (Fixed / Sliding Windows)**:

- **Definición de Ventanas Temporales:** El dataset, ordenado según `encounter_id` como proxy cronológico, se dividirá en 10 ventanas pseudo-temporales secuenciales de tamaño equivalente (simulando períodos anuales), dado que no se dispone de fecha de admisión explícita en el dataset original.
- **Mapeo de Degradación de Rendimiento:** Se evaluarán las métricas clave (F1-score, ROC-AUC) en cada ventana fija subsiguiente sin reentrenar el modelo base inicial (ventanas 1-2) para cuantificar la pérdida de desempeño producto del drift temporal.
- **Monitoreo de Distribución de Features (Data Drift Basico):** Comparación de histogramas y proporciones de las variables clave (ej. frecuencia de uso de Insulina o número de diagnósticos) entre la ventana de referencia y la ventana actual.
- **Protocolo de Reentrenamiento Fijo:** Simulación de reentrenamiento programado desplazando la ventana fija de entrenamiento (Sliding Window de tamaño fijo de 3 ventanas) para verificar si la actualización periódica recupera el rendimiento deseado. El disparo del reentrenamiento se activará cuando el F1-score de la ventana evaluada caiga más de 0.05 puntos respecto al F1-score obtenido en la ventana de referencia (baseline: ventanas 1-2), sirviendo como criterio operativo simple de degradación.
- **Exploración del Tamaño de Ventana:** Conforme a lo indicado en la Sección 3.5 de la consigna, en la Fase 5 se evaluará el impacto del drift bajo distintos tamaños de ventana (ej. 5, 10 y 15 ventanas pseudo-temporales), además de la configuración base de 10 ventanas anuales, para determinar la granularidad óptima de monitoreo.

6.3. Cronograma de Actividades (Roadmap)

Fase	Hito / Entregable	Actividades Clave
Fase 1 (Actual)	Avance 1: Planteamiento y Arquitectura	Definición de objetivos, restricciones, métricas de éxito, diseño del sistema y mini plan de monitoreo.
Fase 2	Análisis EDA & Preprocesamiento Temporal	Limpieza de datos, codificación de diagnósticos, generación de features temporales, división en ventanas pseudo-cronológicas basadas en <code>encounter_id</code> .
Fase 3	Modelado & Evaluación Temporal	Entrenamiento de ElasticNet, XGBoost y LightGBM. Evaluación de la curva de degradación F1/AUC a lo largo de las ventanas.
Fase 4	Simulación de Despliegue	Simulación de pipeline continuo,

Fase	Hito / Entregable	Actividades Clave
	& Ventanas Fijas	actualización por ventana deslizante y balanceo de incertidumbre.
Fase 5	Entrega Final, Documento & Infografía	Elaboración del informe técnico final (8 págs max), código reproducible, infografía del ciclo de vida y sustentación oral.

8. Bibliografía

Drincic, A., Pfeffer, E., Luo, J., & Goldner, W. S. (2017). *The effect of diabetes case management and Diabetes Resource Nurse program on readmissions of patients with diabetes mellitus.* Journal of Clinical & Translational Endocrinology, 8, 29–34. <https://doi.org/10.1016/j.jcte.2017.03.003>

Bhalodkar, A. et al. (2020). *The Effects of a Comprehensive Multidisciplinary Outpatient Diabetes Program on Hospital Readmission Rates in Patients with Diabetes: A Randomized Controlled Prospective Study.* Endocrine Practice, 26(11), 1331-1336. PMID: 33471664.

van Walraven, C., Bennett, C., Jennings, A., Austin, P. C., & Forster, A. J. (2011). *Proportion of hospital readmissions deemed avoidable: a systematic review.* Canadian Medical Association Journal, 183(7), E391–E402. <https://doi.org/10.1503/cmaj.101860>