

Sistema Inteligente Adaptativo para la Predicción de Reingreso Hospitalario en Pacientes Diabéticos

Planificación y Toma de Decisiones en Inteligencia Artificial

Proyecto académico — 2026-I

Autores

Jimena Gurbillon

Maria Surco

Nayeli Guzman

Bihonda Epiquien

Andrea Coa

Docentes

Dra. Aurea Soriano-Vargas

Mg. Robert Buleje

Dataset: *Diabetes 130-US hospitals for years 1999–2008*
UCI Machine Learning Repository

1 Descripción del Problema

Cuando un paciente vuelve a hospitalizarse pocos días después del alta sin que ese regreso estuviera previsto, se habla de un **reingreso hospitalario no planificado**. Para el paciente significa una nueva estancia y, con frecuencia, un deterioro de su salud. Para el hospital significa camas y servicios de emergencia ocupados por casos que en parte podrían haberse evitado. El problema es lo bastante costoso como para que Estados Unidos tenga una política dedicada a él: desde 2012, el *Hospital Readmissions Reduction Program* (HRRP) penaliza económicamente a los hospitales cuyas tasas de reingreso a 30 días superan lo esperado en condiciones como insuficiencia cardíaca, infarto agudo de miocardio y neumonía.

Los pacientes con diabetes merecen una atención particular. La diabetes no figura entre las condiciones objetivo del HRRP, pero acompaña con frecuencia a esas enfermedades, y la forma en que se maneja durante la hospitalización y después del alta influye en que el paciente regrese o no. Tampoco es cierto que el reingreso dependa solo del paciente. Una revisión sistemática encontró que la mediana de reingresos considerados evitables es de 27.1 %, aunque con una variación enorme entre estudios (5 % a 79 %) [18]. Una parte del riesgo está en las comorbilidades, la adherencia al tratamiento o el entorno del paciente. Otra está en el proceso de atención: cómo se concilian los medicamentos, qué tan claras son las indicaciones al alta y si existe un seguimiento posterior.

Esa segunda parte es la que el hospital puede modificar, y el momento natural para hacerlo es el alta. Las intervenciones de transición, como las llamadas de control, las citas tempranas o la asignación de un gestor de caso, reducen los reingresos [8]. Pero consumen tiempo y personal, y no pueden ofrecerse a todos. **El problema pasa entonces de ser solo clínico a ser un problema de decisión:** identificar, entre todos los pacientes que salen del hospital, a quiénes conviene destinar un recurso escaso.

Estimar ese riesgo a partir de registros históricos tiene una dificultad adicional: la práctica clínica cambia. En pocos años pueden cambiar los medicamentos de primera línea, las pautas de tratamiento o la manera de codificar los diagnósticos, y con ellos la relación entre lo que registra el hospital y lo que le ocurre al paciente después. Un modelo que acertaba con los pacientes de un periodo puede equivocarse con los del siguiente sin dar ninguna señal evidente. Por eso, además de predecir, hace falta detectar cuándo y cuánto cambian los datos, ya que de eso depende cada cuánto revisar el sistema y con qué datos actualizarlo.

Este proyecto aborda el problema con un sistema de soporte a la decisión para pacientes diabéticos al momento del alta. Por ejemplo, a un paciente se le ajustó la insulina durante la hospitalización y ya estuvo internado antes. Antes de que reciba el alta, el sistema estima su probabilidad de reingresar en los próximos 30 días y la traduce en un nivel de riesgo **Bajo, Moderado o Alto**. Junto con ese nivel muestra los factores que más pesaron en la estimación y sugiere un plan de seguimiento; si el riesgo es alto, propone una cita presencial prioritaria y una revisión urgente de la medicación. La decisión final es del médico, que puede aceptar, ajustar o descartar la recomendación (esquema *Human-in-the-Loop*). En segundo plano, el sistema evalúa periódicamente sus

propias predicciones y, cuando detecta que empeoran por cambios en los patrones clínicos, se reentrena con datos más recientes.

2 Definición de Objetivos

2.1 Objetivo General

Implementar un sistema inteligente de predicción de reingreso hospitalario a 30 días en pacientes diabéticos que mantenga su desempeño confiable ante los cambios en los datos a lo largo del tiempo y respalde la toma de decisiones clínicas bajo un esquema *Human-in-the-Loop*.

2.2 Objetivos Específicos

1. Analizar el historial clínico de las admisiones hospitalarias y preparar los datos para ser consumidos por modelos de ML.
2. Comparar distintos modelos de clasificación supervisada: ElasticNet, Random Forest, y XGBoost, mediante métricas seleccionadas, con el fin de comprender los factores clínicos asociados al reingreso y determinar el modelo más confiable.
3. Diseñar la arquitectura del sistema, integrando un motor de decisión basado en matrices de utilidad y costos ponderados del error con umbrales adaptables al contexto hospitalario.
4. Diseñar el despliegue del sistema completo en la nube: modelo predictivo, módulo de monitoreo y reentrenamiento.
5. Implementar una estrategia de monitoreo por ventanas temporales que permita detectar oportunamente la degradación del modelo.

3 Definición de Restricciones

Las restricciones que condicionan el diseño son de tres tipos: de **autonomía**, **normativas** y de **alcance geográfico**.

La primera es la **autonomía**. El sistema no puede modificar prescripciones ni emitir altas médicas por su cuenta. Opera bajo un esquema *Human-in-the-Loop*: recomienda un plan de seguimiento y el médico tratante acepta, ajusta o descarta esa recomendación. Esto condiciona el diseño más de lo que parece, porque la salida del sistema no es una acción sino una sugerencia, y debe presentarse con los factores que la explican para que el médico pueda evaluarla.

La segunda es **normativa**. HIPAA regula el manejo de datos de salud identificables, y la regla HTI-1 de la ONC exige transparencia en las herramientas de soporte a la decisión basadas en algoritmos. El dataset del UCI ya viene desidentificado, con los identificadores directos eliminados y las fechas agregadas, pero un despliegue real dentro de un EHR recibiría datos identificables. El pipeline productivo debe replicar esos controles de anonimización antes de que cualquier registro llegue al módulo predictivo, y registrar de forma auditable qué variables influyeron en cada predicción.

La tercera es de **alcance geográfico**, y limita hasta dónde se pueden extender las conclusiones. Los datos provienen de 130 hospitales de Estados Unidos, así que reflejan un sistema de salud específico: su esquema de aseguramiento, sus criterios de admisión y alta, su codificación ICD-9 y su composición demográfica. Los costos que alimentan la matriz de decisión también son estadounidenses. Nada de eso se traslada directamente a otro

Cuadro 1: Métricas de éxito: qué mide cada una y por qué se fijó ese criterio.

Dimensión	Métrica	Criterio de aprobación	Para qué sirve y por qué ese criterio
Técnica	ROC-AUC	$\geq 0,66$ (promedio de ventanas, IC95 %)	Mide si el modelo <i>ordena</i> bien: es la probabilidad de que un paciente que reingresa reciba mayor puntaje que uno que no, sin depender del umbral. El criterio se fija en el techo empírico: los modelos con datos administrativos rara vez superan 0,65–0,70 [7] y con este dataset el mejor reporte es 0,667 [3].
Técnica	PR-AUC y <i>lift</i>	$\geq 0,20$, con <i>lift</i> $\geq 1,8\times$	Mide el desempeño sobre la clase minoritaria (los reingresos), donde la ROC resulta optimista [11]. El <i>lift</i> es PR-AUC dividido entre la prevalencia, e indica cuántas veces mejor que el azar selecciona el modelo. Como la línea base sin capacidad predictiva es la prevalencia, se exige $0,112 \times 1,8 \approx 0,20$.
Decisión	Beneficio neto (DCA)	$> \text{máx}(\text{intervenir a todos, no intervenir})$, para $p \in [0,05, 0,30]$	Responde si vale la pena usar el modelo: convierte <i>VP</i> y <i>FP</i> a una escala común, $VP/n - (FP/n) \cdot p/(1-p)$, y lo compara con las dos políticas por defecto [19]. Un modelo con discriminación moderada puede ser útil igual si prioriza mejor un recurso escaso. El rango cubre p^* en todos los escenarios de sensibilidad (0,09–0,19).
Decisión	Costo esperado / 1,000 altas	$C_{\text{modelo}} < \text{mín}(\text{políticas de referencia})$ en los tres escenarios de la Tabla 4: caso base ($e = 0,18$), optimista ($e = 0,38$) y alta ocupación ($C_r + 25\%$)	Exige que el costo total de gestionar 1,000 altas usando el modelo sea menor que los métodos habituales del hospital. La fórmula $C = C_i(VP + FP) + C_r[FN + VP(1-e)]$ suma: 1) el costo preventivo ($C_i \approx \$550$) aplicado a todos los pacientes detectados ($VP + FP$), y 2) el costo de rehospitalización ($C_r \approx \$16,037$) acumulado por fallos de la IA (FN) o por intervenciones que no lograron evitar el reingreso ($VP(1-e)$), considerando una efectividad preventiva base de 18 % ($e = 0,18$).
Social	Igualdad de oportunidad (razón de FNR)	$[0,87, 1,15]$, en grupos con ≥ 100 reingresos, IC95 %	La FNR es la proporción de pacientes que sí reingresan y no fueron marcados; si es mayor en un grupo, a ese grupo se le niega la intervención con más frecuencia [6]. El mínimo se cuenta en reingresos porque la FNR se calcula solo sobre ellos. Los límites son 1,15 y su recíproco 0,87.
Social	Calibración por subgrupo	pendiente $[0,8, 1,2]$, $ \text{intercepto} \leq 0,2$	Pendiente e intercepto salen de regresar el desenlace sobre $\text{logit}(p)$: la pendiente detecta probabilidades demasiado extremas y el intercepto un sesgo sistemático. Un modelo calibrado en promedio puede subestimar el riesgo de un subgrupo y darle menos alertas. Con tasas base distintas no se pueden cumplir a la vez calibración y paridad de errores [1], por lo que se monitorean ambas.

país. Llevar el sistema a un hospital peruano exigiría recalibrar el modelo con datos locales, recalcular C_r y C_i con costos propios, y repetir la auditoría de equidad con las categorías demográficas que ese contexto use. Los 130 hospitales tampoco son una muestra aleatoria del sistema estadounidense, de modo que la validez externa está acotada incluso dentro del mismo país.

4 Métricas de Éxito

Se establecen tres dimensiones –técnicas, de decisión y sociales/éticas– definidas *a priori* y justificadas en literatura (Tabla 1); los resultados se presentan en la Sección 10.

La Tabla 1 resume los criterios. Se usa la siguiente notación: *VP*, *FP* y *FN* son verdaderos positivos, falsos positivos y falsos negativos, donde “positivo” significa marcar al paciente para intervención; la **prevalencia** es la proporción de reingresos observados (0,112); C_r es el costo de un reingreso; C_i el de la intervención; y e la **eficacia de la intervención**, es decir, la fracción de reingresos que el seguimiento llega a evitar entre los pacientes intervenidos. De ahí sale el umbral óptimo $p^* = C_i/(C_r \cdot e)$: conviene intervenir cuando el ahorro esperado supera el costo de intervenir.

5 Diseño del Sistema de IA y Arquitectura

El sistema opera como una herramienta de soporte integrada en el flujo clínico, no como una aplicación independiente. El usuario principal es el médico tratante o el equipo de enfermería responsable del alta; al finalizar la evaluación clínica, el módulo predictivo se activa automáticamente y despliega el riesgo estimado en la pantalla de “Resumen de Alta” del EHR.

El sistema se concibe como un **pipeline continuo adaptativo** de seis módulos interconectados (Figura 1):

1. **Adquisición e integración de datos:** ingesta continua de registros de alta desde el EHR (demográficos, clínicos, diagnósticos, esquema de medicación); la fuente actual es tabular estructurada, con notas clínicas de texto libre como extensión multimodal futura (Sección 11).
2. **Módulo predictivo adaptativo:** preprocesamiento en tiempo real e inferencia con el modelo activo.
3. **Manejo de incertidumbre:** calibración de probabilidades (Platt / Isotonic, Sección 6) y marcado de “Incertidumbre Alta” cuando el intervalo de confianza cruza un umbral de decisión.
4. **Toma de decisiones y clasificación de riesgo:** matriz de utilidad (Bajo / Moderado / Alto) con




Figura 1: Arquitectura del sistema (seis módulos). El monitoreo de drift retroalimenta al modelo predictivo (reentrenamiento) y al evaluador de incertidumbre/calibración.

umbral dinámico según capacidad hospitalaria.

5. **Acción e intervención:** protocolo de seguimiento ambulatorio, alerta de control a 7 días o cita presencial prioritaria con gestor de caso, según el nivel de riesgo.
6. **Monitoreo de drift:** evaluación periódica del rendimiento y la distribución de *features* por ventanas fijas, con retroalimentación hacia el reentrenamiento (Sección 7).

El pipeline implementado sigue esta arquitectura módulo a módulo (`notebooks/01` a `notebooks/07`): cada vez que el drift dispara un reentrenamiento, el modelo (3) y su calibración (4) se reajustan sobre la ventana nueva.

6 Modelos y Estrategia de Evaluación

La exploración de datos mostró evolución temporal en variables clave, lo que motivó variables de contexto en ventana deslizante y rezagadas/agregadas por periodo como candidatas de *feature engineering* temporal. Antes de modelar, se auditó la preparación de datos con trece pruebas de fuga, dividiendo *train/val/test* en bloques estrictamente secuenciales (Sección 3). La auditoría descartó las variables de contexto (actuaban como proxy del periodo, invalidando las curvas de drift) y corrigió un embargo de latencia insuficiente (EMBARGO: 850 → 2,000); todos los resultados se generaron después de esta corrección.

Se compararon dos enfoques tradicionales — **ElasticNet** (regresión logística regularizada) y **Random Forest** (ensamble de árboles)— y uno más avanzado, **XGBoost** (*gradient boosting*, mayor capacidad para interacciones no lineales entre diagnósticos, medicación y estancia). Cada modelo se ajusta con validación temporal (`TimeSeriesSplit`, 3 folds) sobre el 80 % inicial de la ventana de entrenamiento, y se calibra sobre el 20 % final entre Platt Scaling e Isotonic Regression [10] según cuál minimiza el Brier score.

Cuadro 2: Comparación de modelos, experimento E1 (estático, entrenado en bloques 1–2, evaluado sin reentrenar en bloques 3–10). Se eligió como modelo principal Random Forest

Modelo	ROC-AUC	PR-AUC
ElasticNet	0.652	0.213
RandomForest	0.664	0.215
XGBoost	0.653	0.192

Random Forest se selecciona como modelo principal por su mejor ROC-AUC y PR-AUC iniciales (Tabla 2).

7 Monitoreo y Adaptación ante Data Drift

En cualquier sistema de predicción entrenado con datos históricos existe el riesgo de que, con el tiempo, deje de estar en sintonía con la realidad. A eso se le llama **drift**, y en este proyecto se vigilan dos versiones del mismo fenómeno: los **datos de entrada cambian** (por ejemplo, los pacientes que llegan hoy usan insulina de forma distinta a los de hace cinco años) o **la relación entre esos datos y el resultado cambia** (el mismo perfil de paciente que antes reingresaba poco, ahora reingresa más, porque cambió el protocolo de tratamiento). Lo primero se puede corregir recalibrando; lo segundo obliga a reentrenar el modelo con datos recientes.

7.1 Cómo se simuló el paso del tiempo

El dataset no trae una fecha de alta real, así que se ordenaron los registros por el identificador de cada hospitalización (`encounter_id`), que funciona como un proxy razonable del orden cronológico: para el mismo paciente, el encuentro siguiente casi siempre incluye sus hospitalizaciones previas (84.9 % de las veces, contra apenas 47.4 % si el orden fuera al revés). Con ese orden se armaron **10 bloques** de tamaño similar, cada uno representando, de forma aproximada, un año de operación del hospital.

Sobre esos 10 bloques se probaron cuatro maneras de operar el modelo con el tiempo

- **Desplegar y olvidar:** se entrena una sola vez, al


inicio, y nunca se vuelve a tocar.

- **Reentrenar con todo el historial:** cada año se vuelve a entrenar usando todos los datos acumulados hasta ese momento.
- **Ventana deslizante:** cada año se reentrena usando solo los últimos 3 años, “olvidando” a propósito lo más viejo, que ya no es representativo.
- **Reentrenar solo cuando hay una alerta:** el modelo se queda quieto hasta que el monitoreo detecta una señal clara de que algo cambió (una caída de precisión o un cambio fuerte en los datos de entrada), y recién ahí se actualiza.

Estas dos últimas corresponden a los dos enfoques “ciegos” vs. “informados”, la ventana deslizante reentrena por calendario sin comprobar si hace falta (cuadrante *Olvido*: modelo único, actualización evolutiva), mientras que el disparador solo actúa cuando detecta una señal explícita (cuadrante *Detectores*: modelo único, con *triggers*), igual que algoritmos como ADWIN o Page-Hinkley, pero aplicado tanto a la tasa de error del modelo como a la distribución de los datos.

Un quinto elemento, independiente de estas cuatro estrategias, es el **monitoreo de los datos de entrada**: en cada bloque se revisa si variables clínicas clave (uso de insulina, número de diagnósticos, procedimientos, urgencias) se ven distintas respecto al primer bloque. Esto se hace con una métrica estándar de la industria del riesgo crediticio, el *Population Stability Index* (PSI) [14], que en la práctica funciona como un semáforo: verde si la variable se ve igual, amarillo si cambió un poco, rojo si cambió lo suficiente como para justificar revisión. Este semáforo, junto con la caída de precisión del modelo, es lo que dispara el reentrenamiento en la estrategia “solo cuando hay alerta”.

7.2 Qué tanto se degrada el modelo si nunca se actualiza



Bandas: IC95% por bootstrap. Entrenamiento único en B1–B2, sin reentrenar.

Figura 2: Precisión del modelo (ROC-AUC) a lo largo de los 10 bloques simulados.

La Figura 2 muestra lo que ocurre si el modelo se “despliega y se olvida”: su capacidad de distinguir quién reingresa y quién no empeora de forma constante, sin un evento dramático de por medio — es un desgaste gradual, no un colapso repentino. Con esto se evidencia que, en este problema, el tiempo sí importa y que un chequeo periódico tiene sentido.

Al comparar las cuatro estrategias sobre los mismos años de prueba (Tabla 3), la **ventana deslizante de 3 años** fue la que mejor equilibrio dio entre precisión y estabilidad, y es la que se recomienda para producción.

La estrategia de “reentrenar solo con alerta” es la más económica en cómputo, pero en el periodo evaluado solo se activó una vez, así que hace falta más tiempo de observación para confiar plenamente en ella.

Cuadro 3: Comparación de las cuatro estrategias (bloques 6–10).

Estrategia	ROC-AUC	PR-AUC
Deslizante (3 años)	0.680	0.226
Todo el historial	0.676	0.223
Solo con alerta	0.674	0.222
Desplegar y olvidar	0.662	0.212

7.3 ¿Y el monitoreo de variables por sí solo?

El semáforo de PSI mostró que la mayoría de las variables clínicas se mantiene estable con el tiempo; las excepciones aparecen desde el bloque 7 en adelante, en el número de diagnósticos registrados y el tipo de admisión. Es simplemente la confirmación de que, hacia el final del periodo estudiado, la forma de registrar la información clínica cambió lo suficiente como para justificar una revisión, justo donde más cae la precisión del modelo estático (Figura 2).

8 Capa de Decisión y Caso de Negocio

8.1 Cómo se decide a quién intervenir

Cada paciente se clasifica en riesgo **Bajo**, **Moderado** o **Alto**. Solo los pacientes de Alto Riesgo reciben una intervención de seguimiento (llamada de control + revisión de medicamentos), y como máximo el 15 % de los pacientes de cada periodo puede quedar en esa categoría, para no saturar al personal ni generar “fatiga de alertas” [17]. Los tres números que mueven esta decisión son los siguientes:

- Un reingreso hospitalario le cuesta al hospital, en promedio, **\$16,037** [5].
- Intervenir a un paciente de Alto Riesgo (llamada + conciliación de medicamentos) cuesta **\$550** [Supuesto: estimación del equipo].
- Esa intervención reduce en promedio un **18 %** la probabilidad de que el paciente reingrese [8].

Con esos tres números alcanza para decidir a quién conviene intervenir: si el riesgo de un paciente es alto, el ahorro esperado por evitar su reingreso supera de sobra el costo de la llamada y la revisión de medicamentos.

8.2 Políticas y escenarios de evaluación

Para saber si el modelo vale la pena, se compara contra las dos decisiones que un hospital podría tomar sin él. Estas son las tres **políticas** (columnas de la Tabla 4):

- **Nadie:** no se da seguimiento a ningún paciente; todos los reingresos ocurren y se pagan.
- **Todos:** se interviene a todos los pacientes dados de alta, sin importar su riesgo.
- **Modelo:** se interviene solo a los pacientes que el modelo mantenido al día (ventana deslizante, Sección 7) clasifica como Alto Riesgo, con el tope de 15 %.

Como los tres números anteriores son estimaciones, cada política se evalúa en tres **escenarios** (filas de la tabla). Los escenarios no cambian el modelo, solo los supuestos de costo y eficacia con que se calcula el costo:

- **Caso base:** los valores de arriba ($C_r = \$16,037$, $C_i = \$550$, $e = 0,18$).
- **Optimista:** la intervención funciona mejor de lo esperado ($e = 0,38$). Es el escenario más exigente para el modelo: si intervenir es muy eficaz, intervenir a todos se vuelve competitivo.
- **Alta ocupación:** el hospital está saturado y cada reingreso cuesta un 25 % más ($C_r \approx \$20,046$) [Supuesto: recargo por saturación], con $e = 0,18$.

En todos los casos el costo por cada 1,000 altas se calcula con la fórmula de la Tabla 1, $C = C_i(VP + FP) + C_r[FN + VP(1 - e)]$, y el *ahorro* del modelo es la diferencia con la mejor de las dos políticas de referencia.

Cuadro 4: Costo por cada 1,000 altas (US\$) de cada política en cada escenario. *Ahorro* = mín(Nadie, Todos) – Modelo; un valor negativo indica que el modelo pierde frente a la mejor referencia.

Escenario (e ; C_r)	Nadie	Todos	Modelo	Ahorro
Caso base (0,18; \$16k)	1,822,600	2,044,532	1,797,592	25,008
Optimista (0,38; \$16k)	1,822,600	1,680,012	1,688,841	–8,829
Alta ocupación (0,18; \$20k)	2,278,250	2,418,165	2,224,893	53,357

El modelo es la política más barata en dos de los tres escenarios. Solo en el optimista, donde la intervención es tan eficaz que casi conviene dársela a todos, “Todos” resulta ligeramente más barato. En el caso base, sin dar seguimiento a nadie se gastan \$1,822,600 por cada 1,000 altas, y usando el modelo para elegir a quién intervenir se gastan \$1,797,592: un ahorro de **\$25,008 por cada 1,000 altas**. Esa cifra es la base de todo lo que sigue; lo único que cambia entre los dos casos de abajo es cuántas veces se multiplica.

8.3 El caso de negocio: ¿cuánto vale, y a qué escala?

Ese \$25,008 es un promedio; año a año no es parejo, y ahí está el argumento más fuerte a favor de mantener el sistema al día. La Figura 3 compara, a la escala de una red de ~50,000 altas/año, dos cosas distintas del ahorro total: el ahorro *adicional* de mantener el modelo actualizado frente a dejarlo congelado (“desplegar y olvidar”), en verde, contra lo que cuesta el sistema, en azul. En el año 1 ambos modelos son prácticamente iguales, así que el ahorro adicional (\$46,000) es menor que el costo (\$57,000), que todavía incluye construir el modelo. Desde el año 2 el costo baja a solo mantenimiento (\$12,000/año, prácticamente plano) mientras el ahorro adicional sigue creciendo, de \$159,500 en el año 2 a \$756,000 en el año 7, porque un modelo sin vigilancia no se rompe de golpe, se va quedando obsoleto de a poco (Sección 7). Lo que cuesta mantener el sistema no cambia, pero lo que se pierde por no mantenerlo sí, y cada vez más.




Figura 3: Ahorro adicional de mantener el modelo actualizado frente a un modelo congelado vs. costo total del sistema, año a año, a escala de una red de ~50,000 altas/año.

Lo que cambia el caso de negocio anual, además del tiempo, es **cuántas altas maneja quien lo implementa**. El dataset original viene de una colaboración de **130 hospitales** de EE. UU. [16], así que conviene mirar el caso a esa escala de red, no solo a la de un hospital individual. En ambos casos se usa el ahorro del caso base frente a no intervenir (Tabla 4):

- **Un hospital mediano** [Supuesto: ~3,000 altas de pacientes diabéticos al año — el propio dataset promedia solo 78/hospital/año, pero eso es un subconteo: sus criterios de inclusión (ciertos exámenes de laboratorio, exclusión de fallecidos, etc.) dejan fuera a la mayoría de los diabéticos realmente hospitalizados]: el sistema ahorra **\$75,000 al año**. Construirlo y mantenerlo cuesta \$57,000 el primer año (\$45,000 de desarrollo [Supuesto: equipo pequeño, 2 meses] más \$1,000/mes de cómputo y revisión). El caso ya es positivo, pero ajustado: se recupera lo invertido, con un beneficio neto de \$18,000 el primer año.
- **Una red de ~17 hospitales** (50,000 altas/año en conjunto — una fracción pequeña de los 130 hospitales que aportaron los datos originales, así que es una proyección conservadora, no optimista): el mismo sistema, con la misma inversión de \$57,000, ahorra **\$1.25 millones al año**. En este caso **conviene invertir sin dudar**: la inversión se recupera en unos 17 días y el beneficio neto del primer año (\$1.19 millones) es 21 veces lo que costó construir y mantener el sistema.




Figura 4: Inversión vs. ahorro en el primer año, a dos escalas. La inversión (construir + mantener) es la misma en ambos casos; lo que cambia es cuántas altas absorben ese costo fijo.

Cuadro 6: Resumen de los criterios de aprobación (dos por dimensión), estrategia desplegada (E3, $S = 3$). Se cumplen 5 de 6.

Dimensión	Métrica	Criterio	Resultado	Cumple
Técnica	ROC-AUC	≥ 0.66 (promedio de ventanas)	0.673 (peor bloque 0.646)	✓
Técnica	PR-AUC / lift	≥ 0.20 y lift $\geq 1.8\times$	0.220 / $1.94\times$	✓
Decisión	Beneficio neto (DCA)	$>$ referencias en $p \in [0,05, 0,30]$	supera en el 100 % del rango	✓
Decisión	Costo esperado / 1,000 altas	$<$ mín(referencias), 3 escenarios (Tabla 4)	ahorro \$25,008 (base) y \$53,357 (alta ocupación); $-\$8,829$ (optimista)	✗
Social	Igualdad de oportunidad (FNR)	razón $[0,87, 1,15]$, grupos ≥ 100 reingresos	todos los grupos evaluables dentro del rango	✓
Social	Calibración por subgrupo	pendiente $[0,8, 1,2]$, $ \text{int.} \leq 0.2$	todos los grupos evaluables cumplen (Tabla 5)	✓

La lección de fondo (Figura 4) es que este tipo de sistema tiene un costo de construcción y mantenimiento mayormente **fijo**, mientras que el ahorro crece **linealmente** con el volumen de pacientes. Por eso, en la práctica, quien construye y mantiene un sistema así no suele ser un hospital aislado, sino una red o un proveedor de salud que centraliza el servicio para varios hospitales a la vez (Sección 11) — igual que la propia colaboración de 130 hospitales que hizo posible este dataset.

9 Auditoría de Equidad

Se audita la paridad del sistema por grupo etario (≥ 70 vs. < 70 años) y por **race**, evaluando solo grupos con al menos 100 reingresos observados (Tabla 5).

Cuadro 5: Auditoría de equidad por grupo etario y racial.

Dimensión	Grupo	n	Reingresos	Tasa reingreso	Razón FNR	Cumple FNR
grupo_edad	< 70	27,863	2,967	10.6 %	1.00	✓
grupo_edad	≥ 70	23,636	2,880	12.2 %	1.12	✓
race	AfricanAmerican	9,186	1,018	11.1 %	0.97	✓
race	Asian	375	31	8.3 %	—	n/e
race	Caucasian	38,999	4,514	11.6 %	1.00	✓
race	Desconocido	1,096	102	9.3 %	1.15	✓
race	Hispanic	1,012	98	9.7 %	—	n/e
race	Other	831	84	10.1 %	—	n/e

El criterio de explicabilidad (top-3 factores SHAP, coincidentes con las variables monitoreadas por drift: insulina, diagnósticos, procedimientos y urgencias) se cumple en el 100 % de los casos, y la latencia ($p_{95} = 79,5$ ms) cumple ampliamente la restricción de 2 segundos (Sección 3).

10 Resultados Consolidados y Criterios No Cumplidos

La Tabla 6 consolida el resultado de los seis criterios de éxito (dos por dimensión) bajo la estrategia desplegada (E3, $S = 3$).

De los seis criterios de éxito definidos *a priori*, **se cumplen cinco**. La única excepción es el **costo esperado en el escenario de sensibilidad más optimista** ($e = 0,38$): con una eficacia de intervención tan alta el umbral óptimo baja e “intervenir a todos” iguala al modelo, que pierde por un margen pequeño ($-\$8,829 / 1,000$ altas); en el caso base ($e = 0,18$) y en el de alta ocupación el modelo sigue ganando.

11 Propuesta de Despliegue y Gestión de Riesgos

11.1 Propuesta de despliegue

Se propone una arquitectura de **microservicios** en AWS que separe la inferencia online, el procesamiento de datos y el ciclo MLOps, pues cada componente tiene una carga y una frecuencia de ejecución distintas [15]. El servicio de inferencia conserva juntos el preprocesamiento, la ca-

libración y el modelo de ML para evitar llamadas de red innecesarias y diferencias entre entrenamiento y producción. Este servicio se empaqueta en una imagen Docker versionada en ECR y se ejecuta sobre CPU, ya que el tamaño del modelo no justifican GPU ni infraestructura especializada.

Para el volumen esperado se elige una combinación de FaaS y servicios gestionados: API Gateway privado y Lambda con concurrencia aprovisionada para la inferencia síncrona, y SageMaker Processing, Training, Pipelines y Model Registry para monitoreo, entrenamiento, evaluación y gobierno de versiones. Esto evita administrar máquinas virtuales o un clúster Kubernetes y pagar capacidad permanente. A su vez, el contenedor y la infraestructura como código mantienen la portabilidad: si la carga sostenida supera la capacidad o conveniencia económica de Lambda, la misma imagen puede migrar a SageMaker Real-Time o ECS sin cambiar el contrato con el EHR.

El flujo online es EHR $\rightarrow$ API REST privada $\rightarrow$ Lambda $\rightarrow$ EHR, mediante VPN o Direct Connect. La respuesta contiene únicamente la probabilidad calibrada de reingreso, su incertidumbre y factores explicativos. Por tanto, el modelo es **exclusivamente predictivo**: no recomienda intervenciones, asigna recursos ni ejecuta acciones; el profesional interpreta el resultado y decide fuera del modelo. Si los datos son inválidos o el servicio no está disponible, se devuelve “no evaluado”, nunca una clasificación de bajo riesgo por defecto.

En paralelo, las predicciones, altas y reingresos se almacenan de forma seudónima y versionada en S3. Las etiquetas negativas se publican solo después de 30 días más el retraso de llegada. EventBridge programa el monitoreo y SageMaker genera candidatos E3 con las tres últimas cohortes maduras; una señal E4 puede adelantar su evaluación, pero no desplegarlo automáticamente. Todo candidato pasa por Model Registry, aprobación ML y clínica, ejecución en sombra, canario y rollback, manteniendo trazabilidad sobre datos, código, métricas y versión desplegada [13].

11.2 Riesgos identificados

Los principales riesgos y su mitigación se resumen en la Tabla 7.

12 Conclusiones

El sistema se diseñó, implementó y validó, cumpliendo el objetivo de mantener un desempeño confiable ante los cambios de los datos en el tiempo; la ventana deslizante de 3 años fue la estrategia más sólida frente al modelo estático. La auditoría de fuga de información fue indispensable antes de confiar en las curvas de degradación reportadas. Las métricas cumplen cinco de

Cuadro 7: Riesgos identificados y mitigación.

Riesgo	Descripción	Mitigación
Drift silencioso entre ciclos	Cambio abrupto degrada el modelo antes del siguiente chequeo.	Mayor frecuencia de monitoreo en periodos de alta variabilidad; alertas si $PSI > 0,25$.
Fatiga de alertas clínicas	Exceso de Alto Riesgo reduce la atención a cada alerta [17].	Cupo de 15 % por bloque; monitorear tasa de <i>override</i> .
Inequidad en la selección de Alto Riesgo	Razón de selección entre subgrupos por debajo de la regla del 80 %.	No desplegar sin resolver; evaluar cupos estratificados o post-procesamiento [6].
Fuga en cambios futuros / <code>encounter_id</code> como proxy temporal	Nuevas variables pueden reintroducir fugas (Sección 6); el proxy solo es válido para este dataset histórico.	Repetir la batería de 13 pruebas de auditoria_ <code>leakage.csv</code> antes de integrar; migrar a fecha real de alta y revalidar embargo y ventanas.

los seis criterios definidos a priori; la única excepción es el costo esperado en el escenario optimista ($e = 0,38$), donde intervenir a todos resulta ligeramente más barato, lo que indica que la eficacia real del seguimiento debe validarse antes de desplegar. El caso de negocio muestra que el monitoreo de drift se paga solo frente a su costo de mantenimiento, con un ahorro de \$25,008 por cada 1,000 altas en el caso base, entregando un sistema validado y un valor económico cuantificado.

Bibliografía

- [1] Chouldechova, A. (2017). Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. *Big Data*, 5(2), 153–163.
- [2] Drincic, A., Pfeffer, E., Luo, J., & Goldner, W. S. (2017). The effect of diabetes case management and Diabetes Resource Nurse program on readmissions of patients with diabetes mellitus. *Journal of Clinical & Translational Endocrinology*, 8, 29–34.
- [3] Emi-Johnson, O., & Nkrumah, K. (2025). Predicting hospital readmission risk with machine learning: benchmarks on the Diabetes 130-US hospitals dataset.
- [4] Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys*, 46(4), 1–37.
- [5] Ghabowen, I., et al. (2024). Cost of hospital readmissions attributable to diabetes.
- [6] Hardt, M., Price, E., & Srebro, N. (2016). Equality of opportunity in supervised learning. *Advances in Neural Information Processing Systems (NeurIPS)*, 29.
- [7] Kansagara, D., et al. (2011). Risk prediction models for hospital readmission: a systematic review. *JAMA*, 306(15), 1688–1698.
- [8] Leppin, A. L., et al. (2014). Preventing 30-day hospital readmissions: a systematic review and meta-analysis of randomized trials. *JAMA Internal Medicine*, 174(7), 1095–1107.
- [9] Nawaz. (2026). *How to instrument clinical decision support system response times*. OneUptime.
- [10] Platt, J. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. *Advances in Large Margin Classifiers*, 10(3), 61–74.
- [11] Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3).
- [12] Salim, & Ibrahim. (2026). Calibrated risk prediction for hospital readmission with nested cross-validation. *Research Square* (preprint).

- [13] Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems (NeurIPS)*, 28.
- [14] Siddiqi, N. (2006). *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. Wiley.
- [15] Soriano-Vargas, A. (2026). *Concept Drift* [Diapositivas de clase, Planificación y Toma de Decisiones en IA]. UTEC.
- [16] Strack, B., DeShazo, J. P., Gennings, C., Olmo, J. L., Ventura, S., Cios, K. J., & Clore, J. N. (2014). Impact of HbA1c measurement on hospital readmission rates: analysis of 70,000 clinical database patient records. *BioMed Research International*, 2014.
- [17] van der Sijs, H., et al. (2006). Overriding of drug safety alerts in computerized physician order entry. *Journal of the American Medical Informatics Association*, 13(2), 138–147.
- [18] van Walraven, C., Bennett, C., Jennings, A., Austin, P. C., & Forster, A. J. (2011). Proportion of hospital readmissions deemed avoidable: a systematic review. *Canadian Medical Association Journal*, 183(7), E391–E402.
- [19] Vickers, A. J., & Elkin, E. B. (2006). Decision curve analysis: a novel method for evaluating prediction models. *Medical Decision Making*, 26(6), 565–574.