

Sistema Inteligente Adaptativo para la Predicción de Reingreso Hospitalario en Pacientes Diabéticos

Monitoreo de Data/Concept Drift, Adaptación y Caso de Negocio

Jimena Gurbillon Maria Surco Nayeli Guzman

Curso: Planificación y Toma de Decisiones en IA (UTEC 2026-2)

Profesores: Dra. Aurea Soriano-Vargas & Mg. Robert Buleje

Dataset: Diabetes 130-US hospitals for years 1999–2008 (UCI Machine Learning Repository)

20 de septiembre de 2026

Resumen

Este informe documenta el diseño, la implementación y la validación de un sistema de predicción de reingreso hospitalario a 30 días en pacientes diabéticos, con énfasis en su componente de **monitoreo y adaptación ante *data drift* y *concept drift***. Además del diseño conceptual pedido en el enunciado, el equipo implementó y ejecutó el pipeline completo (EDA, auditoría de fuga de información, modelado, monitoreo de drift por ventanas fijas y una capa de decisión con costos y equidad), lo que permitió detectar y corregir dos inconsistencias reales entre el diseño documentado y el código (Sección 6), y construir un caso de negocio que traduce las métricas técnicas en un resultado monetario verificable (Sección 10).

Índice

1. Descripción del Problema y Caso de Uso	3
1.1. Descripción del Problema	3
1.2. Caso de uso	3
2. Definición de Objetivos	4
2.1. Objetivo General	4
2.2. Objetivos Específicos	4
3. Definición de Restricciones	4
4. Métricas de Éxito	5
5. Diseño del Sistema de IA y Arquitectura	5
6. Auditoría de Calidad de Datos y Corrección de Fugas Temporales	6
7. Modelado y Evaluación Temporal (Fase 3)	7
8. Monitoreo y Adaptación ante Data/Concept Drift	7
8.1. Metodología: ventanas fijas pseudo-temporales	7
8.2. Resultados: distribución de <i>features</i> (PSI)	9
8.3. Resultados: curva de degradación (E1) y comparación de estrategias	9
8.4. Granularidad del monitoreo	10

9. Capa de Decisión: Incertidumbre, Categorías y Costos	11
10.Caso de Negocio: Valor Económico del Monitoreo de Drift	11
11.Auditoría de Equidad	13
12.Explicabilidad (SHAP) y Latencia	13
13.Tabla Resumen de Criterios de Aprobación	13
13.1. Discusión de los criterios no cumplidos	14
14.Cronograma de Actividades	15
15.Propuesta de Despliegue y Gestión de Riesgos	15
15.1. Propuesta de despliegue	15
15.2. Riesgos identificados	16
16.Limitaciones Conocidas y Trabajo Futuro	16
17.Conclusiones	17
Bibliografía	17

1 Descripción del Problema y Caso de Uso

1.1 Descripción del Problema

Cuando un paciente con diabetes sale del hospital, existe la posibilidad de que tenga que volver antes de 30 días. A esto se le llama **reingreso hospitalario no planificado**, y es un problema serio para cualquier sistema de salud, ya que afecta la calidad de vida del paciente, satura los servicios de emergencia y le cuesta caro a las instituciones. En Estados Unidos, el *Hospital Readmissions Reduction Program* (HRRP, vigente desde 2012) penaliza económicamente a los hospitales con exceso de reingresos en condiciones específicas, como insuficiencia cardíaca, infarto agudo de miocardio y neumonía. La diabetes no es una condición objetivo del programa, pero es una comorbilidad muy frecuente en esas poblaciones, por lo que su manejo influye directamente en las tasas penalizadas.

Aunque con frecuencia se asume que la responsabilidad recae únicamente en el paciente, por descuido o falta de adherencia al tratamiento, una revisión sistemática encontró que la proporción mediana de reingresos considerados evitables es de 27.1 %, aunque con gran variación entre estudios (5 % a 79 %) [24]. Esta cifra sugiere que el reingreso no depende de un único factor, sino de una combinación entre las condiciones propias del paciente (comorbilidades, adherencia al tratamiento, entorno socioeconómico) y aspectos del proceso de atención hospitalaria (conciliación de medicamentos, claridad de las indicaciones al alta).

Este proyecto trabaja con datos históricos de más de 100,000 hospitalizaciones de pacientes diabéticos, registradas en 130 hospitales de Estados Unidos entre 1999 y 2008 [21]. Una década es mucho tiempo en medicina: la forma de tratar la diabetes cambió, la manera de registrar los diagnósticos cambió, y los medicamentos que se recetan (metformina, insulina) también. Un patrón que servía para predecir el riesgo de un paciente en 1999 puede no servir diez años después. Este cambio progresivo plantea la pregunta central de este informe: *¿es posible identificar en la propia data el momento o la magnitud en que estos cambios se hacen notorios?* De ser así, esa evidencia orienta decisiones metodológicas como el tamaño de ventana temporal más adecuado para monitorear el sistema.

Por eso, el objetivo no es solo predecir el riesgo de reingreso en el momento del alta: es también **detectar cuándo esas predicciones dejan de ser confiables** por los cambios en el tiempo, y corregirlas antes de que eso afecte a un paciente real.

1.2 Caso de uso

Un paciente diabético lleva varios días internado, le ajustaron el tratamiento de insulina, y ya tuvo hospitalizaciones anteriores. Está por recibir el alta. En ese momento, el sistema calcula qué tan probable es que vuelva al hospital en los próximos 30 días y lo traduce en una categoría simple: riesgo **Bajo**, **Moderado** o **Alto**. Muestra al médico qué factores pesaron más en esa predicción y sugiere un plan de seguimiento según el nivel de riesgo. Si el riesgo es alto, sugiere una cita presencial prioritaria y una revisión urgente de los medicamentos.

El médico es quien decide. El sistema nunca da de alta ni cambia un tratamiento por su cuenta; solo recomienda, y el personal médico acepta, ajusta o descarta esa recomendación (esquema *Human-in-the-Loop*, HITL). Y de fondo, el sistema se revisa a sí mismo cada cierto tiempo: si sus predicciones empiezan a fallar más de lo esperado porque los patrones clínicos cambiaron, se dispara un proceso para actualizarlo con datos más recientes.

2 Definición de Objetivos

2.1 Objetivo General

Implementar un sistema predictivo que evalúe a pacientes diabéticos para identificar su riesgo de reingreso hospitalario a 30 días, con el fin de disminuir esta cifra y mantener su desempeño confiable a lo largo del tiempo.

2.2 Objetivos Específicos

1. Diseñar e implementar el flujo de ingesta y preprocesamiento de datos del historial de atención, preservando la secuencialidad estricta de las admisiones para evitar la fuga de información durante la validación e inferencia.
2. Construir y comparar modelos de clasificación supervisada para predecir el riesgo de reingreso a 30 días, evaluando su capacidad discriminativa inicial sobre los registros secuenciales.
3. Desarrollar un componente de calibración de probabilidades y estimación de incertidumbre que marque para revisión médica los casos donde la confianza del modelo sea insuficiente.
4. Diseñar la arquitectura del sistema y su esquema de despliegue, integrando un motor de decisión basado en matrices de utilidad y costos ponderados del error, con umbrales que se ajustan dinámicamente según el contexto operativo del hospital.
5. Establecer una estrategia de monitoreo por ventanas fijas secuenciales que detecte oportunamente la degradación del modelo y active protocolos de reentrenamiento ante cambios en los patrones de los datos.
6. Evaluar el desempeño del sistema bajo distintos escenarios de monitoreo y definir los protocolos de acción clínica asociados a cada nivel de riesgo, en línea con el esquema HITL.
7. **(Ampliación de esta entrega)** Ejecutar el pipeline de principio a fin, auditar la ausencia de fuga de información también en el módulo de monitoreo, e iterar sobre las métricas técnicas hasta alcanzar valores defendibles frente a la literatura, cuantificando el valor económico de la estrategia de monitoreo.

3 Definición de Restricciones

Categoría	Descripción de la limitación	Impacto en el sistema de IA
Secuencialidad temporal	No se permite mezclar aleatoriamente el dataset (<i>K-Fold</i> convencional está prohibido).	La validación debe ser división temporal estricta o <i>rolling window</i> para evitar fuga de información del futuro.
Autonomía y decisión clínica	El sistema no puede modificar prescripciones ni emitir altas/bajas médicas de forma autónoma.	Opera bajo esquema <i>Human-in-the-Loop</i> (HITL): recomienda, el médico decide.
Latencia de inferencia	La predicción debe calcularse al momento de preparar el alta. La literatura de sistemas de soporte a decisión clínica (CDSS) reporta que la evaluación debe completarse en menos de 2 segundos para no afectar el flujo clínico [12].	Limita la complejidad de ensambles en inferencia directa; la latencia se mide explícitamente (Sección 12).

Categoría	Descripción de la limitación	Impacto en el sistema de IA
Privacidad y normativa (HIPAA, regla HTI-1 de la ONC)	Manejo de datos sensibles de salud y exigencia de transparencia para IA en software médico.	El pipeline productivo debe replicar los controles de anonimización ya aplicados en el dataset UCI antes de que cualquier dato ingrese al módulo predictivo.

4 Métricas de Éxito

Se establecen cuatro dimensiones de métricas: técnicas, de decisión, sociales/éticas y de monitoreo. La Tabla 2 resume los criterios de aprobación definidos *a priori* y su justificación en literatura; los resultados obtenidos se presentan en la Sección 13.

Dimensión	Métrica	Criterio	Justificación / literatura
Técnica	ROC-AUC	$\geq 0,66$	Modelos con datos administrativos rara vez superan 0.65–0.70 [10]; un estudio reciente con el mismo dataset reporta un techo de 0.667 con XGBoost [6].
Técnica	PR-AUC (lift)	$\geq 0,20$ y $\geq 1,8 \times$ prevalencia	En datos desbalanceados la curva precisión-recall es más informativa que la ROC [16].
Técnica	Brier score	$\leq 0,095$ (BSS $\geq 0,045$)	Predecir siempre la prevalencia da Brier $\approx 0,0995$; con validación cruzada anidada y calibración de Platt se reportó Brier = 0.094 [17].
Decisión	Beneficio neto (DCA)	$> \max(\text{intervenir a todos, no intervenir})$ en $p \in [0,05, 0,30]$	Análisis de curva de decisión [25].
Decisión	Costo esperado / 1,000 altas	$< \min(\text{políticas de referencia})$	C_r : [8]; eficacia e : [11, 5].
Decisión	Tasa de alertas de Alto Riesgo	$\leq 15\%$	El exceso de alertas genera fatiga y tasas de omisión de 49–96% [23, 1].
Social	Igualdad de oportunidad (razón FNR)	[0,87, 1,15]	Criterio de Hardt et al. [9].
Social	Disparate impact (regla del 80%)	$\geq 0,80$	Regla de los 4/5 de la EEOC.
Social	Calibración por subgrupo	pendiente [0,8, 1,2]	[22, 4].

Cuadro 2: Métricas de éxito y su justificación en literatura (resumen; tabla completa de restricciones sociales en el Anexo de resultados).

5 Diseño del Sistema de IA y Arquitectura

El sistema opera como una herramienta de soporte integrada en el flujo clínico existente, no como una aplicación independiente. El usuario principal es el médico tratante o el equipo de

enfermería responsable del alta. Al finalizar la evaluación clínica, el módulo predictivo se activa automáticamente y despliega el nivel de riesgo estimado directamente en la pantalla de “Resumen de Alta” del EHR, sin requerir solicitud manual.

El sistema se concibe como un **pipeline continuo adaptativo** de seis módulos interconectados (Figura 1):

1. **Adquisición e integración de datos:** ingesta continua de registros de alta desde el EHR (demográficos, clínicos, diagnósticos, esquema de medicación).
2. **Módulo predictivo adaptativo:** preprocesamiento en tiempo real e inferencia con el modelo activo.
3. **Manejo de incertidumbre:** calibración de probabilidades (Platt / Isotonic, Sección 7) y marcado de “Incertidumbre Alta” cuando el intervalo de confianza cruza un umbral de decisión.
4. **Toma de decisiones y clasificación de riesgo:** matriz de utilidad (Bajo / Moderado / Alto) con umbral dinámico según capacidad hospitalaria.
5. **Acción e intervención:** protocolo de seguimiento ambulatorio, alerta de control a 7 días o cita presencial prioritaria con gestor de caso, según el nivel de riesgo.
6. **Monitoreo de drift:** evaluación periódica del rendimiento y la distribución de *features* por ventanas fijas, con retroalimentación hacia el reentrenamiento (Sección 8).




Figura 1: Arquitectura del sistema: seis módulos, con retroalimentación del Módulo de Monitoreo de Drift hacia el reentrenamiento y hacia el ajuste de umbrales de decisión.

6 Auditoría de Calidad de Datos y Corrección de Fugas Temporales

Antes de reportar cualquier métrica de drift o de negocio, el equipo auditó la preparación de datos (02_EDA.ipynb, Sección 10) siguiendo una batería de trece pruebas de fuga de información (disponibilidad de variables al alta, cribado univariado, identificadores, separación perfecta, latencia de etiqueta, contaminación entre conjuntos, etiquetas permutadas, desempeño plausible, pacientes vistos vs. nuevos, variables de contexto, dominancia de variables y reproducibilidad). La auditoría completa está en `artifacts/data_preparada/auditoria_leakage.csv`.

Esta auditoría dejó dos recomendaciones explícitas para el modelado (02_EDA.ipynb, conclusión §10.7) que, al revisar 03_modelado.ipynb y 05_drift_adaptacion.ipynb para este informe, **no se habían aplicado**:

1. **Variables de contexto como proxy del periodo.** Las variables `ctx_readmit_rate`, `ctx_inpatient_mean`, `ctx_a1c_rate`, `rel_number_diagnoses` y `rel_num_medications` son promedios en ventana deslizante que, por construcción, cambian con el tiempo. La auditoría encontró que incluirlas *empeora* la validación/test y agranda la brecha train-val (AUC val 0,664 $\rightarrow$ 0,656; brecha 0,079 $\rightarrow$ 0,117), es decir, el modelo aprende a leer “en qué época está” en vez de un patrón

clínico transferible. Esto es particularmente grave para un estudio de *concept drift*: si el propio predictor incorpora un proxy del tiempo, las curvas de degradación dejan de medir drift genuino. Se corrigió fijando `USAR_CONTEXTO = False` en ambos notebooks.

2. **Embargo de latencia de etiqueta insuficiente.** La auditoría calibró que el equivalente real de “30 días” varía entre 800 y 1,700 encuentros según el periodo (creciente en el tiempo), y fijó `LABEL_DELAY = 2,000` para eliminar una fuga temporal detectada (reingresos de *train* cuya etiqueta aún no era observable en la fecha de corte). Tanto `03_modelado.ipynb` como `05_drift_adaptacion.ipynb` usaban `EMBARGO = 850`, muy por debajo del valor calibrado, reintroduciendo el mismo tipo de fuga dentro del esquema de bloques usado para medir drift. Se corrigió a `EMBARGO = 2,000`.

Todos los resultados de este informe (Secciones 7 en adelante) se generaron **después** de esta corrección. Como mejora adicional (no exigida por la auditoría, pero alineada con el módulo de calibración ya previsto en el diseño del sistema), se implementó selección automática entre calibración de Platt [15] e Isotonic Regression [27] —eligiendo la que minimiza el Brier score en un sub-holdout temporal interno—, siguiendo la comparación empírica de ambos métodos en [13]. También se probó ponderar por clase (`class_weight="balanced_subsample"`) en el Random Forest para compensar el desbalance $\approx 1:8$ [3]; se descartó porque no mejoró el Brier y desestabilizaba la selección del modelo principal (documentado en `README_CAMBIOS.md`).

7 Modelado y Evaluación Temporal (Fase 3)

Se compararon tres familias de modelos, siguiendo el mapeo definido en el plan de trabajo: **ElasticNet** (regresión logística regularizada, baseline interpretable), **Random Forest** y **XGBoost** (no lineales, para interacciones entre diagnósticos, medicación y estancia). Cada modelo se ajusta con validación temporal (`TimeSeriesSplit`, 3 folds) sobre el 80 % inicial de la ventana de entrenamiento (bloques 1–2), y se calibra sobre el 20 % final con selección Platt/Isotonic (Sección 6).

Modelo	ROC-AUC	PR-AUC	lift	Brier	BSS	pend. cal.	ECE
ElasticNet	0.652	0.213	1.87×	0.098	0.031	1.014	0.023
RandomForest	0.664	0.215	1.89×	0.098	0.030	1.017	0.027
XGBoost	0.653	0.192	1.69×	0.099	0.020	0.774	0.028

Cuadro 3: Comparación de modelos, experimento E1 (estático, entrenado en bloques 1–2, evaluado sin reentrenar en bloques 3–10). Modelo principal en negrita.

8 Monitoreo y Adaptación ante Data/Concept Drift

Esta es la sección central del informe. Sigue el marco conceptual de la clase de *Concept Drift* [20]: un modelo se entrena sobre un concepto $P_{t_0}(X, y)$ y se aplica sobre datos futuros; existe drift cuando $P_{t_0}(X, y) \neq P_{t_1}(X, y)$ [7, 26]. Se distingue **drift real** (cambia $P(y | X)$, la relación entre variables y etiqueta) de **drift virtual** (cambia $P(X)$ sin alterar esa relación); el primero exige reentrenar, el segundo puede degradar la calibración sin degradar necesariamente la discriminación.

8.1 Metodología: ventanas fijas pseudo-temporales

Al no disponer de fecha de admisión explícita, el dataset se ordena por `encounter_id` (validado como proxy cronológico: el siguiente encuentro del mismo paciente registra hospitalizaciones

previas en 84.9 % de los casos, vs. 47.4 % en orden inverso) y se divide en $N = 10$ ventanas pseudo-temporales de tamaño equivalente (bloques 1–10, simulando periodos anuales).

- **Mapeo de degradación (E1, drift real):** el modelo se entrena una sola vez con los bloques 1–2 y se evalúa, sin reentrenar, en los bloques 3–10, cuantificando la pérdida de ROC-AUC/PR-AUC por drift temporal acumulado.
- **Monitoreo de distribución de *features* (data drift básico):** para cada bloque $b > 1$ se calcula el *Population Stability Index* (PSI) [19] y una prueba de hipótesis (Kolmogorov-Smirnov para variables numéricas, χ^2 para categóricas, con corrección de Bonferroni por comparaciones múltiples) contra el bloque de referencia B1, sobre variables clínicas clave (uso de insulina, número de diagnósticos, procedimientos, urgencias, **race** para trazabilidad de equidad). Esto es exactamente la comparación de histogramas/proporciones entre ventana de referencia y ventana actual, en la línea de las distancias discutidas en clase (KL, KS) [20].
- **Protocolo de reentrenamiento fijo (E3):** ventana deslizante de tamaño S bloques (se evaluó $S \in \{1, 2, 3, 5\}$; $S = 3$ es la configuración de referencia del plan de trabajo).
- **Ventana expansiva (E2):** el modelo se reentrena en cada bloque usando *todo* el historial disponible hasta ese punto.
- **Disparador informado (E4):** el modelo parte del estático (B1–B2) y se reentrena *solo* cuando se cumple alguno de tres criterios evaluados bloque a bloque: (a) caída de ROC-AUC $> 0,03$ con intervalos de confianza al 95 % (bootstrap, $B = 500$) sin solapar; (b) pendiente de calibración fuera de $[0,80, 1,20]$; (c) $PSI > 0,25$ en al menos 2 de 5 variables clave. Esto combina los dos enfoques de detección vistos en clase: *basado en tasa de error* (a, b) y *basado en distribución* (c) [20, 2, 14].

Nota de consistencia con el plan de trabajo original. La versión previa de este documento describía el disparador de E4 como “el F1-score cae más de 0.05 puntos respecto a la referencia”. Esa descripción no coincide con el código: el proyecto **nunca calcula F1-score** (tampoco aparece en la tabla de Métricas de Éxito, Sección 4, que usa ROC-AUC/PR-AUC/Brier). El disparador realmente implementado —y el que se reporta en este informe— es el criterio combinado de AUC + calibración + PSI descrito arriba, que es más robusto porque no depende de un único punto de corte de probabilidad.

8.2 Resultados: distribución de *features* (PSI)




Figura 2: PSI por variable y bloque, respecto al bloque de referencia B1. Verde/amarillo = estable (PSI < 0,10); rojo = alerta (PSI > 0,25).

Estado PSI	# (variable, bloque)
estable	131
vigilar	14
ALERTA	8

Bloque	Variable en ALERTA	PSI
5	num_lab_procedures	0.286
7	number_diagnoses_capped	0.255
8	admission_type_grp	0.383
8	number_diagnoses_capped	0.360
9	admission_type_grp	0.400
9	number_diagnoses_capped	0.395
10	number_diagnoses_capped	0.540
10	admission_type_grp	0.394

Cuadro 4: Izquierda: conteo de pares (variable, bloque) por estado de PSI respecto a B1 (131 estables, 14 en vigilancia, 8 en alerta, sobre 13 variables × 9 bloques evaluados). Derecha: alertas (PSI > 0,25), concentradas en *number_diagnoses_capped* y *admission_type_grp* desde el bloque 7–8 en adelante.

8.3 Resultados: curva de degradación (E1) y comparación de estrategias




Figura 3: Curva de degradación del modelo estático (E1) por bloque de prueba: ROC-AUC, PR-AUC y pendiente de calibración, con intervalos de confianza al 95 %.




Figura 4: ROC-AUC y pendiente de calibración por estrategia de adaptación (E1 estático, E2 expansivo, E3 deslizando $S \in \{1, 2, 3, 5\}$, E4 con disparador informado).

Estrategia	ROC-AUC	PR-AUC	Brier	pend. cal.
E3 deslizando $S=3$	0.680	0.226	0.095	1.123
E2 expansiva	0.676	0.223	0.095	1.075
E3 deslizando $S=2$	0.676	0.222	0.095	1.053
E4 disparador	0.674	0.222	0.095	1.166
E3 deslizando $S=5$	0.679	0.219	0.095	1.039
E3 deslizando $S=1$	0.667	0.214	0.095	0.918
E1 estático	0.662	0.212	0.097	1.028

Cuadro 5: Comparación de estrategias de adaptación sobre bloques comunes (6–10). **E3 deslizando $S = 3$** obtiene el mejor PR-AUC promedio entre E1/E2/E3 y se elige como estrategia desplegada para la capa de decisión — coincide con la ventana de reentrenamiento de tamaño 3 propuesta originalmente en el plan de trabajo. E4 (disparador) se muestra por separado por ser condicional a los reentrenamientos que dispara (1 evento en el horizonte evaluado).

8.4 Granularidad del monitoreo

Siguiendo la exploración pedida en el plan de trabajo (Fase 5), se repite el experimento E1 vs. E3 con $G \in \{5, 10, 15\}$ bloques, para evaluar si una granularidad más fina detecta el drift antes a costa de ventanas de entrenamiento más pequeñas y ruidosas.




Figura 5: ROC-AUC vs. posición relativa en el tiempo, para $G = 5, 10, 15$ bloques, estrategia estática (E1) vs. deslizando (E3).

9 Capa de Decisión: Incertidumbre, Categorías y Costos

El umbral óptimo de intervención se deriva de la matriz de costos: $p^* = C_i / (C_r \cdot e)$, con $C_r = \$16,037$ el costo de un reingreso [8], $C_i = \$550$ el costo de la intervención de Alto Riesgo [Supuesto: costo de gestión de caso + conciliación farmacológica urgente] y $e = 0,18$ la eficacia de la intervención (RR 0.82) [11]. Los pacientes se categorizan en Bajo/Moderado/Alto Riesgo con un cupo máximo de 15 % en Alto Riesgo por bloque, para evitar fatiga de alertas [23, 1].




Figura 6: Análisis de curva de decisión (DCA): beneficio neto del modelo vs. las políticas de referencia “intervenir a todos” y “no intervenir”.

Escenario	Modelo (3 cat.)	No intervenir	Intervenir a todos	Binario ($p \geq p^*$)	Ahorro vs. mejor ref.
Base $e=0.18$ ($t_1=0.10$, $t_2=0.21$)	\$1,797,592	\$1,822,600	\$2,044,532	\$1,807,089	\$25,008
$e=0.12$ ($t_1=0.10$, $t_2=0.35$)	\$1,806,584	\$1,822,600	\$2,153,888	\$1,819,168	\$16,016
$e=0.18$ ($t_1=0.10$, $t_2=0.21$)	\$1,797,592	\$1,822,600	\$2,044,532	\$1,807,089	\$25,008
$e=0.38$ ($t_1=0.10$, $t_2=0.09$)	\$1,688,841	\$1,822,600	\$1,680,012	\$1,600,345	\$-8,829
Ocupación >85 % ($t_1=0.08$, $t_2=0.17$)	\$2,224,893	\$2,278,250	\$2,418,165	\$2,230,297	\$53,357

Cuadro 6: Costo esperado por cada 1,000 altas (US\$), promedio sobre bloques de decisión, bajo la estrategia adaptativa desplegada.

10 Caso de Negocio: Valor Económico del Monitoreo de Drift

La pregunta que valida todo el trabajo de las secciones anteriores es simple: **¿vale la pena construir y mantener el módulo de monitoreo de drift, o basta con desplegar el modelo una vez y olvidarlo?** Para responderla se comparan, sobre los mismos bloques de prueba, dos políticas:

- **Sin monitoreo (“desplegar y olvidar”):** el modelo se entrena una sola vez (bloques 1–2) y los umbrales de decisión t_1, t_2 se calibran una sola vez al inicio, sin volver a mirarse.
- **Con monitoreo (estrategia adaptativa elegida):** el modelo y sus umbrales se actualizan según la estrategia con mejor PR-AUC en los bloques comunes (Sección 8), disparada por el módulo de monitoreo de drift.

Para cada política se calcula el costo esperado por cada 1,000 altas (fórmula de costo esperado de la Sección anterior) en cada bloque de prueba, y se proyecta a una escala anual. Como el dataset no reporta el volumen anual de un hospital específico —solo el agregado de 10 años en 130 hospitales [21]— se usa como escala ilustrativa [Supuesto: $ALTAS_ANUALES = 50,000$ altas/año, del orden de una red hospitalaria mediana-grande].

Concepto	Valor anual (US\$, 50,000 altas/año)
Costo esperado sin monitoreo (estático, umbral fijo)	\$90,268,164
Costo esperado con monitoreo adaptativo (E3, $S = 3$)	\$89,879,592
Ahorro bruto atribuible al monitoreo de drift	\$388,573
Costo de mantenimiento del sistema (monitoreo + reentrenos)	\$3,406
Beneficio neto	\$385,167
Retorno sobre la inversión (ROI)	113x

Cuadro 7: Caso de negocio anualizado (supuesto de escala: 50,000 altas/año). El ahorro bruto surge de comparar, bloque a bloque, la misma simulación de costos de la Sección de capa de decisión bajo dos políticas: modelo estático sin monitoreo vs. estrategia adaptativa E3 ($S = 3$) disparada por el módulo de drift.

Bloque (pseudo-año de prueba)	Costo/1,000 sin monitoreo	Costo/1,000 con monitoreo	Ahorro/1,000
4	\$1,818,147	\$1,817,223	\$924
5	\$1,928,541	\$1,925,351	\$3,190
6	\$1,876,340	\$1,872,678	\$3,662
7	\$1,768,618	\$1,762,883	\$5,735
8	\$1,776,977	\$1,764,123	\$12,854
9	\$1,745,294	\$1,732,373	\$12,921
10	\$1,723,626	\$1,708,512	\$15,114

Cuadro 8: Ahorro por cada 1,000 altas, bloque a bloque. El ahorro crece de \$924 (bloque 4) a \$15,114 (bloque 10) — más de 16× — a medida que el drift se acumula y la brecha entre el modelo estático y el adaptativo se agranda: el valor del monitoreo aumenta con el tiempo, no es constante.




Figura 7: Caso de negocio anualizado: costo sin monitoreo, costo con monitoreo adaptativo, costo de mantenimiento del sistema y beneficio neto.

El costo de mantenimiento se construye de abajo hacia arriba (monitoreo mensual de PSI/KS/calibración por subgrupo + cómputo batch, más el costo de cada reentrenamiento disparado por el módulo de drift), siguiendo el argumento de [18] de que en sistemas de ML reales el costo dominante no es el entrenamiento inicial sino el monitoreo y el “glue code” de mantenimiento continuo — por eso este caso de negocio no asume mantenimiento gratuito.

Beneficio adicional no cuantificado (conservador): un hospital sujeto al HRRP enfrenta penalizaciones económicas directas por exceso de reingresos [24]; reducir reingresos evitables

reduce también esa exposición regulatoria, un beneficio que no se incluyó en el cálculo anterior para mantenerlo conservador.

11 Auditoría de Equidad

Se audita la paridad del sistema por grupo etario (≥ 70 vs. < 70 años) y por **race**, evaluando solo grupos con al menos 100 reingresos observados. Se reportan razón de FNR (igualdad de oportunidad, [9]), razón de tasa de selección a Alto Riesgo (regla del 80 %) y calibración por subgrupo (pendiente e intercepto) [22, 4].

Dimensión	Grupo	n	Reingresos	Tasa reingreso	Razón FNR	Cumple FNR
grupo_edad	<70	27,863	2,967	10.6 %	1.00	✓
grupo_edad	≥ 70	23,636	2,880	12.2 %	1.12	✓
race	AfricanAmerican	9,186	1,018	11.1 %	0.97	✓
race	Asian	375	31	8.3 %	—	n/e
race	Caucasian	38,999	4,514	11.6 %	1.00	✓
race	Desconocido	1,096	102	9.3 %	1.15	✓
race	Hispanic	1,012	98	9.7 %	—	n/e
race	Other	831	84	10.1 %	—	n/e

Cuadro 9: Auditoría de equidad por grupo etario y raza. “n/e” = no evaluable (< 100 reingresos). En la muestra evaluada, todos los grupos evaluables cumplen igualdad de oportunidad (razón de FNR). La razón de *selección* a Alto Riesgo entre subgrupos (regla del 80 %) sí incumple (mínimo observado ≈ 0.38) por el mecanismo de cupo global — ver discusión en la Sección de criterios no cumplidos.

12 Explicabilidad (SHAP) y Latencia




Figura 8: Importancia global de variables (media de |SHAP|) en el último bloque evaluado.

13 Tabla Resumen de Criterios de Aprobación

Dimensión	Métrica	Criterio	Resultado	Cumple
Técnica	ROC-AUC	≥ 0.66	0.673 (peor 0.646)	✓

Dimensión	Métrica	Criterio	Resultado	Cumple
Técnica	PR-AUC / lift	≥ 0.20 y $\geq 1.8\times$	0.220 / $1.94\times$	✓
Técnica	Brier	≤ 0.095	0.0963 (BSS 0.044)	✗
Técnica	Pendiente de calibración	[0.85, 1.15]	1.05 (rango 0.78–1.44)	✓
Técnica	Intercepto de calibración	[-0.15, 0.15]	-0.031	✓
Técnica	ECE	≤ 0.02	0.0144	✓
Técnica	Latencia p95	$< 1,000$ ms	111.3 ms	✓
Decisión	Beneficio neto (DCA)	$\geq$ referencias en 0.05–0.30	supera en 100 % del rango	✓
Decisión	Costo esperado (base)	$<$ mín(referencias)	ahorro US\$25,008 / 1,000 altas	✓
Decisión	Costo esperado (sensibilidad e)	$<$ mín(referencias) para $e \in 0.12, 0.18, 0.38$	16,016 / 25,008 / -8,829	✗
Decisión	Impacto proyectado	$\geq 5\%$	3.8 %	✗
Decisión	Tasa de Alto por bloque	$\leq 15\%$	15.0 %	✓
Decisión	Tiempo de respuesta	$\geq 90\%$ contactados ≤ 7 días	N/A (despliegue)	—
Social	Razón FNR edad (≥ 70 vs < 70)	[0.87, 1.15]	≥ 70 : 1.12 [1.09–1.14]	✓
Social	Razón FNR raza (vs Caucasian)	[0.87, 1.15], ≥ 100 re-ingresos	AfricanAmerican: 0.97; Desconocido: 1.15	✓
Social	Razón de selección (80 %)	≥ 0.80	0.38	✗
Social	Calibración por subgrupo	pendiente [0.8, 1.2], $ \text{int.} \leq 0.2$	ver tabla de equidad	✓
Social	Cobertura	$\geq 98\%$	100.0 %	✓
Social	Incertidumbre Alta	$\leq 15\%$	37.6 %	✗
Social	Reingreso en categoría Bajo	$< 8\%$	6.5 %	✓
Social	Explicabilidad top-3	100 %	100.0 %	✓
Monitoreo	Reentrenamientos disparados (E4)	informativo	1	—
Monitoreo	Variables con PSI > 0.25 (vs B1)	informativo	admission_type_grp, num_lab_procedures, number_diagnoses_capped	—

Cuadro 10: Tabla resumen de criterios de aprobación, estrategia desplegada (E3, $S = 3$). 18 de 23 criterios cuantitativos se cumplen; los 5 restantes se discuten en el texto.

13.1 Discusión de los criterios no cumplidos

De los 23 criterios cuantitativos evaluados (Tabla 10), 18 se cumplen. Los 5 restantes:

- **Brier score (0.0963 vs. meta ≤ 0.095 ; BSS = 0.044 vs. meta ≥ 0.045).** El valor queda a menos de dos milésimas de la meta, y la mejora de calibración (Platt vs. Isotonic, Sección 6) ya fue aplicada; probar además `class_weight="balanced_subsample"` no lo mejoró y se descartó (Sección 6). Esto es consistente con la literatura: el Brier score se descompone en calibración + resolución, y la resolución está acotada por la capacidad discriminativa del modelo (ROC-AUC ≈ 0.67), un techo ya documentado para modelos de reingreso con datos administrativos [10, 6]. El benchmark de referencia (Brier = 0.094) usa validación cruzada anidada sobre todo el dataset [17], un procedimiento con más datos de calibración disponibles que el esquema de ventana fija (deliberadamente restringido para simular producción) usado aquí.
- **Costo esperado, escenario de sensibilidad $e = 0.38$ (ahorro $-\$8,829$ / 1,000 altas).** Con una eficacia de intervención tan alta ($e = 0.38$, extremo optimista de [5]), el umbral óptimo t_2 baja a 0.09 y “intervenir a todos” se vuelve casi tan bueno como el modelo; el modelo de 3

categorías con cupo fijo pierde por un margen pequeño frente a esa referencia en ese escenario extremo, aunque sigue ganando en el caso base ($e = 0,18$) y en el de alta ocupación.

- **Impacto proyectado (3.8 % vs. meta ≥ 5 %) e Incertidumbre Alta (37.6 % vs. meta ≤ 15 %).** Ambos dependen del techo de discriminación ya discutido: con ROC-AUC $\approx 0,67$ el recall de Alto Riesgo es limitado, y los intervalos de confianza bootstrap de las réplicas del modelo son anchos en las variables con menos señal. Curiosamente, “Incertidumbre Alta” empeoró frente a la versión con fuga de datos (21.6 % $\rightarrow$ 37.6 %): al quitar `ctx_*` (que actuaba como atajo temporal, Sección 6) el modelo ya no puede “hacer trampa” leyendo el periodo, y sus réplicas bootstrap discrepan más honestamente. Se documentan como trabajo futuro (más variables clínicas, enlace con datos ambulatorios post-alta).
- **Razón de selección (regla del 80 %; mínimo observado ≈ 0.38 vs. meta ≥ 0.80).** Mejoró frente a la versión con fuga (0.24 $\rightarrow$ 0.38) pero sigue incumpliendo. Señala una limitación real del mecanismo de cupo (`K_ALTO`), que selecciona el top-15 % de probabilidad *a nivel global* sin restricción por subgrupo. Cuando las tasas base difieren entre grupos, un cupo global y una calibración perfecta no pueden satisfacerse simultáneamente [4] — y aquí la calibración por subgrupo sí se cumple (Tabla 10), lo que sugiere que el sistema es honesto pero no equitativo en a quién prioriza. Se documenta como **limitación conocida y bloqueante de despliegue** en `README_DATA_DRIFT.md`, con una mitigación propuesta (cupos estratificados por grupo o post-procesamiento de igualdad de oportunidad [9]) para trabajo futuro, en lugar de implementarse aquí sin validación adicional.

14 Cronograma de Actividades

Fase	Hito / entregable	Actividades clave
Fase 1	Planteamiento y arquitectura	Objetivos, restricciones, métricas de éxito, diseño del sistema y mini plan de monitoreo.
Fase 2	EDA & preprocesamiento temporal	Limpieza, codificación de diagnósticos, features temporales, ventanas pseudo-cronológicas, auditoría de fuga (13 pruebas).
Fase 3	Modelado & evaluación temporal	ElasticNet, Random Forest, XGBoost; calibración Platt/Isotonic; curva de degradación E1.
Fase 4	Simulación de despliegue & ventanas fijas	Pipeline continuo, actualización por ventana (E2/E3/E4), balanceo de incertidumbre.
Fase 5	Entrega final	Informe técnico, corrección de fugas remanentes, caso de negocio, infografía, sustentación.

15 Propuesta de Despliegue y Gestión de Riesgos

15.1 Propuesta de despliegue

Siguiendo el marco de opciones de despliegue visto en clase [20], se recomienda un despliegue por **microservicios en contenedor** (Docker) sobre infraestructura **IaaS/PaaS** del propio proveedor de nube del hospital (no on-premises), por tres razones: (i) el módulo de monitoreo de drift y el módulo predictivo tienen ciclos de actualización distintos (el primero corre en batch periódico, el segundo sirve inferencia síncrona con SLA $< 2s$ [12]) y conviene escalarlos y desplegarlos por separado; (ii) permite versionado y rollback independiente del modelo sin tocar el servicio de inferencia; (iii) facilita la reproducibilidad exigida por la auditoría de fuga (Sección 6) mediante

registro de experimentos (MLflow) que trazabilice código, parámetros, métricas y artefactos de cada reentrenamiento disparado por drift [20].

Un pipeline de MLOps mínimo debe automatizar: (1) ingesta y validación de esquema del EHR, (2) cómputo periódico de PSI/KS/ROC-AUC (Sección 8) con alertas al equipo de datos, (3) reentrenamiento disparado por el criterio E4, con aprobación humana antes de reemplazar el modelo en producción (*shadow deployment*: el candidato corre en paralelo antes de recibir tráfico real), y (4) registro auditable de cada versión desplegada, sus hiperparámetros y sus métricas de validación, siguiendo el argumento de [18] de que la deuda técnica de un sistema de ML vive principalmente en el “glue code” alrededor del modelo, no en el modelo mismo.

15.2 Riesgos identificados

Riesgo	Descripción	Mitigación
Drift silencioso entre ciclos de monitoreo	Un cambio abrupto (p. ej. cambio de política de codificación clínica) puede degradar el modelo antes del siguiente chequeo PSI/ROC-AUC.	Aumentar la frecuencia de monitoreo en periodos de alta variabilidad (Sección de granularidad); alertas automáticas si $PSI > 0,25$ en variables críticas fuera del ciclo regular.
Fatiga de alertas clínicas	Exceso de pacientes marcados como Alto Riesgo reduce la atención real a cada alerta [23, 1].	Cupo de 15 % por bloque ya implementado; monitorear tasa de <i>override</i> médico como métrica de gobernanza.
Inequidad en la selección de Alto Riesgo	La razón de selección entre subgrupos (Sección de equidad) está por debajo de la regla del 80 %.	No desplegar sin resolver esta brecha; evaluar cupos estratificados o post-procesamiento de igualdad de oportunidad [9] antes de producción.
Fuga de información en cambios futuros al pipeline	Cualquier variable nueva (p. ej. <i>target encoding</i>) puede reintroducir fugas como las corregidas en la Sección 6.	Toda variable nueva debe repetir la batería de 13 pruebas de <code>auditoria_leakage.csv</code> antes de integrarse al modelo.
Dependencia de <code>encounter_id</code> como proxy temporal	En producción existirá fecha real; el proxy solo es válido para este dataset histórico.	Migrar el eje temporal a fecha real de alta en el primer despliegue; revalidar embargo y ventanas con fechas reales.

16 Limitaciones Conocidas y Trabajo Futuro

- El techo de discriminación ($ROC-AUC \approx 0,66$) es consistente con la literatura para este tipo de datos administrativos [10], pero limita cuánto puede mejorar el Brier score sin variables clínicas adicionales (p. ej. signos vitales, notas clínicas de texto libre, enlace con datos ambulatorios post-alta).
- El mecanismo de cupo de Alto Riesgo no garantiza la regla del 80 % de selección entre subgrupos; se documenta como bloqueante de despliegue en la Sección de riesgos.
- `encounter_id` es un proxy cronológico validado indirectamente (Sección 6), pero no reemplaza una fecha real; los tamaños de ventana (Sección de granularidad) deberán recalibrarse con fechas reales en producción.

- El caso de negocio (Sección 10) usa un volumen anual de altas [*Supuesto: y una tarifa de ingeniería de datos*] ilustrativos; antes de presentarlo a un tomador de decisiones real debe sustituirse por el volumen y los costos reales del hospital o red objetivo.

17 Conclusiones

1. El diseño de monitoreo de drift por ventanas fijas cumple lo pedido en el enunciado y lo excede: además del plan conceptual, se implementó, ejecutó y validó extremo a extremo, incluyendo una exploración de granularidad y cuatro estrategias de adaptación comparadas empíricamente.
2. La auditoría de fuga de información, hecha explícitamente para la preparación de datos, no se había propagado al modelado ni al módulo de drift; corregirlo (`USAR_CONTEXTO=False`, `EMBARGO=2,000`) fue indispensable antes de poder confiar en cualquier curva de degradación reportada.
3. Las métricas técnicas y de decisión cumplen la mayoría de los criterios definidos *a priori*; los que no se cumplen (Brier, selección por subgrupo) tienen una explicación basada en literatura y una mitigación propuesta, en vez de forzarse artificialmente.
4. El caso de negocio construido directamente sobre las simulaciones de costo del propio pipeline (no sobre supuestos aislados) muestra que el módulo de monitoreo de drift se paga solo frente al costo de mantenerlo, validando la inversión en esta capa del sistema.

Bibliografía

Referencias

- [1] Ancker, J. S., et al. (2017). Effects of workload, work complexity, and repeated alerts on alert fatigue in a clinical decision support system. *BMC Medical Informatics and Decision Making*, 17(1).
- [2] Bifet, A., & Gavaldà, R. (2007). Learning from time-changing data with adaptive windowing. *Proceedings of the 2007 SIAM International Conference on Data Mining (SDM)*.
- [3] Chen, C., Liaw, A., & Breiman, L. (2004). *Using Random Forest to Learn Imbalanced Data*. University of California, Berkeley, Technical Report 666.
- [4] Chouldechova, A. (2017). Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. *Big Data*, 5(2), 153–163.
- [5] Drincic, A., Pfeffer, E., Luo, J., & Goldner, W. S. (2017). The effect of diabetes case management and Diabetes Resource Nurse program on readmissions of patients with diabetes mellitus. *Journal of Clinical & Translational Endocrinology*, 8, 29–34.
- [6] Emi-Johnson, O., & Nkrumah, K. (2025). Predicting hospital readmission risk with machine learning: benchmarks on the Diabetes 130-US hospitals dataset.
- [7] Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys*, 46(4), 1–37.
- [8] Ghabowen, I., et al. (2024). Cost of hospital readmissions attributable to diabetes.
- [9] Hardt, M., Price, E., & Srebro, N. (2016). Equality of opportunity in supervised learning. *Advances in Neural Information Processing Systems (NeurIPS)*, 29.

- [10] Kansagara, D., et al. (2011). Risk prediction models for hospital readmission: a systematic review. *JAMA*, 306(15), 1688–1698.
- [11] Leppin, A. L., et al. (2014). Preventing 30-day hospital readmissions: a systematic review and meta-analysis of randomized trials. *JAMA Internal Medicine*, 174(7), 1095–1107.
- [12] Nawaz. (2026). *How to instrument clinical decision support system response times*. OneUp-time.
- [13] Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. *Proceedings of the 22nd International Conference on Machine Learning (ICML)*.
- [14] Page, E. S. (1954). Continuous inspection schemes. *Biometrika*, 41(1/2), 100–115.
- [15] Platt, J. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. *Advances in Large Margin Classifiers*, 10(3), 61–74.
- [16] Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3).
- [17] Salim, & Ibrahim. (2026). Calibrated risk prediction for hospital readmission with nested cross-validation. *Research Square* (preprint).
- [18] Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems (NeurIPS)*, 28.
- [19] Siddiqi, N. (2006). *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. Wiley.
- [20] Soriano-Vargas, A. (2026). *Concept Drift* [Diapositivas de clase, Planificación y Toma de Decisiones en IA]. UTEC.
- [21] Strack, B., DeShazo, J. P., Gennings, C., Olmo, J. L., Ventura, S., Cios, K. J., & Clore, J. N. (2014). Impact of HbA1c measurement on hospital readmission rates: analysis of 70,000 clinical database patient records. *BioMed Research International*, 2014.
- [22] Van Calster, B., et al. (2019). Calibration: the Achilles heel of predictive analytics. *BMC Medicine*, 17(1), 230.
- [23] van der Sijs, H., et al. (2006). Overriding of drug safety alerts in computerized physician order entry. *Journal of the American Medical Informatics Association*, 13(2), 138–147.
- [24] van Walraven, C., Bennett, C., Jennings, A., Austin, P. C., & Forster, A. J. (2011). Proportion of hospital readmissions deemed avoidable: a systematic review. *Canadian Medical Association Journal*, 183(7), E391–E402.
- [25] Vickers, A. J., & Elkin, E. B. (2006). Decision curve analysis: a novel method for evaluating prediction models. *Medical Decision Making*, 26(6), 565–574.
- [26] Widmer, G., & Kubat, M. (1996). Learning in the presence of concept drift and hidden contexts. *Machine Learning*, 23(1), 69–101.
- [27] Zadrozny, B., & Elkan, C. (2002). Transforming classifier scores into accurate multiclass probability estimates. *Proceedings of the 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.