

Sistema Inteligente Adaptativo para la Predicción de Reingreso Hospitalario en Pacientes Diabéticos

Monitoreo de Data/Concept Drift, Adaptación y Caso de Negocio

Jimena Gurbillon Maria Surco Nayeli Guzman Bihonda Epiquien
Andrea Coa

Curso: Planificación y Toma de Decisiones en IA (UTEC 2026-I)

Profesores: Dra. Aurea Soriano-Vargas & Mg. Robert Buleje

Dataset: Diabetes 130-US hospitals for years 1999–2008 (UCI Machine Learning Repository)

22 de septiembre de 2026

Resumen

Este informe documenta el diseño, la implementación y la validación de un sistema de predicción de reingreso hospitalario a 30 días en pacientes diabéticos, con énfasis en su componente de **monitoreo y adaptación ante *data drift* y *concept drift***. Además del diseño conceptual, el equipo implementó y ejecutó el pipeline completo (EDA, auditoría de fuga de información, modelado, monitoreo de drift por ventanas fijas y una capa de decisión con costos y equidad), y construyó un caso de negocio que traduce las métricas técnicas en un resultado monetario verificable.

Índice

1. Descripción del Problema	3
2. Definición de Objetivos	3
2.1. Objetivo General	3
2.2. Objetivos Específicos	3
3. Definición de Restricciones	3
4. Métricas de Éxito	4
5. Diseño del Sistema de IA y Arquitectura	4
6. Modelos y Estrategia de Evaluación	5
7. Monitoreo y Adaptación ante Data/Concept Drift	6
7.1. Metodología: ventanas fijas pseudo-temporales	6
7.2. Resultados: distribución de <i>features</i> (PSI)	6
7.3. Resultados: curva de degradación (E1) y comparación de estrategias	7
7.4. Granularidad del monitoreo	7
8. Capa de Decisión y Caso de Negocio	7
9. Auditoría de Equidad	8
10. Resultados Consolidados y Criterios No Cumplidos	8
11. Propuesta de Despliegue y Gestión de Riesgos	9
11.1. Propuesta de despliegue	9
11.2. Riesgos identificados	9
12. Conclusiones	10
Bibliografía	10

1 Descripción del Problema

Cuando un paciente diabético es dado de alta, existe el riesgo de que reingrese al hospital antes de 30 días (**reingreso hospitalario no planificado**). Esto afecta su calidad de vida, satura los servicios de emergencia y genera costos altos para las instituciones. En EE. UU., el *Hospital Readmissions Reduction Program* (HRRP, desde 2012) penaliza a los hospitales por exceso de reingresos en condiciones como insuficiencia cardíaca, infarto agudo de miocardio y neumonía. La diabetes no es una condición objetivo del programa, pero es una comorbilidad frecuente en esas poblaciones, por lo que su manejo influye en las tasas penalizadas.

Aunque suele asumirse que la responsabilidad recae en el paciente (descuido, falta de adherencia), una revisión sistemática encontró que la mediana de reingresos evitables es 27.1 % (rango: 5 %–79 %) [18]. Esto sugiere que el reingreso depende tanto de factores del paciente (comorbilidades, adherencia, entorno socioeconómico) como del proceso de atención hospitalaria (conciliación de medicamentos, claridad de indicaciones al alta). Distinguir el peso de cada factor permite diseñar intervenciones más precisas.

Este proyecto usa datos históricos de más de 100,000 hospitalizaciones de pacientes diabéticos en 130 hospitales de EE. UU. entre 1999 y 2008 [16]. En esa década cambiaron el manejo de la diabetes, el registro de diagnósticos y los medicamentos recetados (metformina, insulina), por lo que un patrón predictivo de 1999 puede no funcionar diez años después. Esto plantea la pregunta: *¿se puede identificar en los datos el momento o la magnitud de estos cambios?* Esa evidencia orientaría decisiones metodológicas, como la ventana temporal óptima para monitorear el sistema.

Por eso, el objetivo no es solo predecir el riesgo de reingreso al alta, sino también **detectar cuándo esas predicciones dejan de ser confiables** por cambios en el tiempo, y corregirlas antes de que afecten a un paciente real.

Un paciente diabético, con tratamiento de insulina ajustado y hospitalizaciones previas, está por recibir el alta. El sistema calcula la probabilidad de reingreso en 30 días y la traduce en riesgo **Bajo, Moderado o Alto**, mostrando al médico los factores más influyentes y sugiriendo un plan de seguimiento; si el riesgo es alto, sugiere una cita presencial prioritaria y una revisión urgente de los medicamentos. El médico decide: el sistema solo recomienda (esquema *Human-in-the-Loop*). Además, se revisa a sí mismo periódicamente, y si sus predicciones fallan más de lo esperado por cambios en los patrones clínicos, se dispara un proceso de actualización con datos recientes.

2 Definición de Objetivos

2.1 Objetivo General

Implementar un sistema inteligente de predicción de reingreso hospitalario a 30 días en pacientes diabéticos que, a partir del análisis del historial clínico de admisiones y del diseño de una arquitectura de modelado y monitoreo continuo, mantenga su desempeño confiable ante los cambios en los datos a lo largo del tiempo y respalde la toma de decisiones clínicas bajo un esquema *Human-in-the-Loop*.

2.2 Objetivos Específicos

1. **Análisis y comparación de la información.** Analizar el historial clínico secuencial de las admisiones hospitalarias –preservando su orden temporal durante el preprocesamiento para evitar la fuga de información– y comparar distintos modelos de clasificación supervisada y estrategias de calibración de probabilidades, con el fin de comprender los factores clínicos asociados al reingreso y determinar el enfoque más confiable para estimar el riesgo a 30 días.
2. **Diseño del sistema de IA y su arquitectura.** Diseñar la arquitectura del sistema, integrando un motor de decisión basado en matrices de utilidad y costos ponderados del error con umbrales adaptables al contexto hospitalario, y una estrategia de monitoreo por ventanas temporales que permita detectar oportunamente la degradación del modelo.
3. **Implementación, integración y despliegue.** Implementar, integrar y desplegar de punta a punta el pipeline de datos, el modelo predictivo y el módulo de monitoreo, evaluando su desempeño bajo distintos escenarios y estableciendo los protocolos de acción clínica según el nivel de riesgo, para obtener como resultado final un sistema validado cuyo valor económico se cuantifica mediante un caso de negocio.

3 Definición de Restricciones

Categoría	Descripción de la limitación	Impacto en el sistema de IA
Secuencialidad temporal	No se permite mezclar aleatoriamente el dataset (<i>K-Fold cross-validation</i> convencional está prohibido).	La validación debe ser división temporal estricta o <i>rolling window</i> para evitar fuga de información del futuro.
Autonomía y decisión clínica	El sistema no puede modificar prescripciones médicas ni emitir bajas o altas médicas de forma 100 % autónoma.	Opera bajo esquema <i>Human-in-the-Loop</i> (HITL): recomienda planes de seguimiento, el médico tratante decide.
Latencia de inferencia	La predicción debe calcularse al preparar el alta médica. La literatura de sistemas de soporte a decisión clínica (CDSS) reporta que la evaluación debe completarse en menos de 2 segundos para no afectar el flujo clínico [9].	Limita la complejidad de ensambles en inferencia directa: el riesgo se calcula automáticamente al revisar el resumen de alta en el EHR, sin demoras perceptibles (latencia medida en la Sección 10).
Privacidad y normativa (HIPAA, regla HTI-1 de la ONC)	HIPAA: manejo de datos sensibles de salud protegidos por normativas de privacidad. ONC: transparencia para la IA en software médico.	El pipeline productivo debe replicar los controles de anonimización ya aplicados en el dataset UCI (eliminación de identificadores directos, agregación de fechas) antes de que cualquier dato ingrese al módulo predictivo, dado que un despliegue real manejaría datos identificables sujetos a HIPAA.

4 Métricas de Éxito

Se establecen tres dimensiones –técnicas, de decisión y sociales/éticas– definidas *a priori* y justificadas en literatura (Tabla 2); los resultados se presentan en la Sección 10.

Dimensión	Métrica	Criterio de aprobación	Justificación / literatura
Técnica	ROC-AUC	$\geq 0,66$ (promedio de ventanas, IC95 %)	Modelos con datos administrativos rara vez superan 0.65–0.70 [7]; un estudio reciente con este dataset reporta un techo de 0.667 con XGBoost [3].
Técnica	PR-AUC (lift)	$\geq 0,20$, con lift $\geq 1,8 \times$ sobre prevalencia	En datos desbalanceados la curva precisión-recall es más informativa que la ROC [11]; la línea base equivale a la prevalencia ($0,112 \times 1,8 \approx 0,20$).
Técnica	Brier score	$\leq 0,095$ (Brier skill score $\geq 0,045$)	Predecir siempre la prevalencia da Brier $\approx 0,0995$; con validación cruzada anidada y calibración de Platt se reportó Brier = 0,094 [12].
Decisión	Beneficio neto (DCA)	$> \text{máx}(\text{intervenir a todos, no intervenir})$ para $p \in [0,05, 0,30]$	Análisis de curva de decisión [19]; el rango cubre el umbral óptimo $p^* = C_i / (C_r \cdot e)$ bajo todo el análisis de sensibilidad ($p^* \approx 0,09\text{--}0,29$).
Decisión	Costo esperado / 1,000 altas	$C_{\text{modelo}} < \text{mín}(\text{políticas de referencia})$ caso base $e = 0,18$ y sensibilidad $e \in \{0,12, 0,38\}$	$C = C_i(VP + FP) + C_r(FN + VP(1 - e))$. $C_r \approx \$16,037$ [5]; $e = 0,18$ del RR= 0,82 [8]; sensibilidad con $e = 0,12$ [2] y $e = 0,38$ (peso FN:FP 10:1). $C_i \approx \$550$.
Decisión	Impacto proyectado (reducción relativa de reingresos)	$\geq 5\%$, calculado como $e \times \text{recall}_{\text{Alto Riesgo}}$	Proyección, no medición: el dataset es observacional y no contiene intervenciones. Techo teórico fijado por la proporción de reingresos evitables, mediana 27.1 % (5–79 %) [18].
Social	Igualdad de oportunidad (razón de FNR)	$[0,87, 1,15]$ entre grupos con ≥ 100 reingresos, IC95 %	Criterio de igualdad de oportunidad [6].
Social	<i>Disparate impact</i> (regla del 80 %)	$\geq 0,80$ en la tasa de selección a alerta preventiva entre grupos	Regla de los 4/5 de la EEOC; se aplica sobre quién recibe la alerta, no sobre la tasa de error del modelo.
Social	Calibración por subgrupo	pendiente $[0,8, 1,2]$, $ \text{intercepto} \leq 0,2$ por grupo	Auditar la calibración dentro de cada subgrupo es crítico [1]: equidad y calibración perfectas no son simultáneamente alcanzables si difieren las tasas base.

Cuadro 2: Métricas de éxito y su justificación en literatura.

5 Diseño del Sistema de IA y Arquitectura

El sistema opera como una herramienta de soporte integrada en el flujo clínico, no como una aplicación independiente. El usuario principal es el médico tratante o el equipo de enfermería responsable del alta; al finalizar la evaluación clínica, el módulo predictivo se activa automáticamente y despliega el riesgo estimado en la pantalla de “Resumen de Alta” del EHR.

El sistema se concibe como un **pipeline continuo adaptativo** de seis módulos interconectados (Figura 1):

1. **Adquisición e integración de datos:** ingesta continua de registros de alta desde el EHR (demostráficos, clínicos, diagnósticos, esquema de medicación); la fuente actual es tabular estructurada, con notas clínicas de texto libre como extensión multimodal futura (Sección 11).
2. **Módulo predictivo adaptativo:** preprocesamiento en tiempo real e inferencia con el modelo activo.
3. **Manejo de incertidumbre:** calibración de probabilidades (Platt / Isotonic, Sección 6) y marcado de “Incertidumbre Alta” cuando el intervalo de confianza cruza un umbral de decisión.
4. **Toma de decisiones y clasificación de riesgo:** matriz de utilidad (Bajo / Moderado / Alto) con umbral dinámico según capacidad hospitalaria.
5. **Acción e intervención:** protocolo de seguimiento ambulatorio, alerta de control a 7 días o cita presencial prioritaria con gestor de caso, según el nivel de riesgo.
6. **Monitoreo de drift:** evaluación periódica del rendimiento y la distribución de *features* por ventanas fijas, con retroalimentación hacia el reentrenamiento (Sección 7).




Figura 1: Arquitectura del sistema (seis módulos). El monitoreo de drift retroalimenta al modelo predictivo (reentrenamiento) y al evaluador de incertidumbre/calibración.

El pipeline implementado sigue esta arquitectura módulo a módulo (`notebooks/01` a `notebooks/07`): cada vez que el drift dispara un reentrenamiento, el modelo (3) y su calibración (4) se reajustan sobre la ventana nueva.

6 Modelos y Estrategia de Evaluación

La exploración de datos mostró evolución temporal en variables clave, lo que motivó variables de contexto en ventana deslizante y rezagadas/agregadas por periodo como candidatas de *feature engineering* temporal. Antes de modelar, se auditó la preparación de datos con trece pruebas de fuga, dividiendo train/val/test en bloques estrictamente secuenciales (Sección 3). La auditoría descartó las variables de contexto (actuaban como proxy del periodo, invalidando las curvas de drift) y corrigió un embargo de latencia insuficiente (EMBARGO: 850 $\rightarrow$ 2,000); todos los resultados se generaron después de esta corrección.

Se compararon dos enfoques tradicionales –**ElasticNet** (regresión logística regularizada) y **Random Forest** (ensamble de árboles)– y uno más avanzado, **XGBoost** (*gradient boosting*, mayor capacidad para interacciones no lineales entre diagnósticos, medicación y estancia). Cada modelo se ajusta con validación temporal (`TimeSeriesSplit`, 3 folds) sobre el 80 % inicial de la ventana de entrenamiento, y se calibra sobre el 20 % final entre Platt Scaling e Isotonic Regression [10] según cuál minimiza el Brier score.

Modelo	ROC-AUC	PR-AUC	lift	Brier	BSS	pend. cal.	ECE
ElasticNet	0.652	0.213	1.87×	0.098	0.031	1.014	0.023
RandomForest	0.664	0.215	1.89×	0.098	0.030	1.017	0.027
XGBoost	0.653	0.192	1.69×	0.099	0.020	0.774	0.028

Cuadro 3: Comparación de modelos, experimento E1 (estático, entrenado en bloques 1–2, evaluado sin reentrenar en bloques 3–10). Modelo principal en negrita.

Random Forest (en negrita) se selecciona como modelo principal por su mejor ROC-AUC y PR-AUC iniciales (Tabla 3).

7 Monitoreo y Adaptación ante Data/Concept Drift

Esta es la sección central del informe. Sigue el marco conceptual de la clase de *Concept Drift* [15]: un modelo se entrena sobre un concepto $P_{t_0}(X, y)$ y se aplica sobre datos futuros; existe drift cuando $P_{t_0}(X, y) \neq P_{t_1}(X, y)$ [4]. Se distingue **drift real** (cambia $P(y | X)$, la relación entre variables y etiqueta) de **drift virtual** (cambia $P(X)$ sin alterar esa relación); el primero exige reentrenar, el segundo puede degradar la calibración sin degradar necesariamente la discriminación.

7.1 Metodología: ventanas fijas pseudo-temporales

Al no disponer de fecha de admisión explícita, el dataset se ordena por `encounter_id` (validado como proxy cronológico: el siguiente encuentro del mismo paciente registra hospitalizaciones previas en 84.9 % de los casos, vs. 47.4 % en orden inverso) y se divide en $N = 10$ ventanas pseudo-temporales de tamaño equivalente (bloques 1–10, simulando periodos anuales).

- **Mapeo de degradación (E1, drift real):** el modelo se entrena una sola vez con los bloques 1–2 y se evalúa, sin reentrenar, en los bloques 3–10, cuantificando la pérdida de ROC-AUC/PR-AUC por drift temporal acumulado.
- **Monitoreo de distribución de *features* (data drift básico):** para cada bloque $b > 1$ se calcula el *Population Stability Index* (PSI) [14] y una prueba de hipótesis (Kolmogorov-Smirnov para variables numéricas, χ^2 para categóricas, con corrección de Bonferroni por comparaciones múltiples) contra el bloque de referencia B1, sobre variables clínicas clave (uso de insulina, número de diagnósticos, procedimientos, urgencias, *race* para trazabilidad de equidad).
- **Protocolo de reentrenamiento fijo (E3):** ventana deslizante de tamaño S bloques (se evaluó $S \in \{1, 2, 3, 5\}$; $S = 3$ es la configuración de referencia del plan de trabajo).
- **Ventana expansiva (E2):** el modelo se reentrena en cada bloque usando *todo* el historial disponible hasta ese punto.
- **Disparador informado (E4):** el modelo parte del estático (B1–B2) y se reentrena *solo* cuando se cumple alguno de tres criterios evaluados bloque a bloque: (a) caída de ROC-AUC $> 0,03$ con intervalos de confianza al 95 % (bootstrap, $B = 500$) sin solapar; (b) pendiente de calibración fuera de $[0,80, 1,20]$; (c) PSI $> 0,25$ en al menos 2 de 5 variables clave. Esto combina detección basada en tasa de error (a, b) y basada en distribución (c), los dos enfoques vistos en clase [15].

Nota de consistencia con el plan de trabajo original. Una versión previa describía el disparador de E4 como “el F1-score cae más de 0.05 puntos respecto a la referencia”; el proyecto **nunca calcula F1-score** (ver Métricas de Éxito: ROC-AUC/PR-AUC/Brier). El disparador realmente implementado es el criterio combinado AUC + calibración + PSI descrito arriba, más robusto que un único punto de corte.

7.2 Resultados: distribución de *features* (PSI)




Figura 2: PSI por variable y bloque, respecto al bloque de referencia B1. Verde/amarillo = estable (PSI $< 0,10$); rojo = alerta (PSI $> 0,25$).

Estado PSI	# (variable, bloque)	Bloque	Variable en ALERTA	PSI
estable	131	5	num_lab_procedures	0.286
vigilar	14	7	number_diagnoses_capped	0.255
ALERTA	8	8	admission_type_grp	0.383
		8	number_diagnoses_capped	0.360
		9	admission_type_grp	0.400
		9	number_diagnoses_capped	0.395
		10	number_diagnoses_capped	0.540
		10	admission_type_grp	0.394

Cuadro 4: Izquierda: conteo de pares (variable, bloque) por estado de PSI respecto a B1 (131 estables, 14 en vigilancia, 8 en alerta, sobre 13 variables $\times$ 9 bloques evaluados). Derecha: alertas (PSI $> 0,25$), concentradas en `number_diagnoses_capped` y `admission_type_grp` desde el bloque 7–8 en adelante.

7.3 Resultados: curva de degradación (E1) y comparación de estrategias




Figura 3: Curva de degradación del modelo estático (E1) por bloque de prueba: ROC-AUC, PR-AUC y pendiente de calibración, con intervalos de confianza al 95 %.

Estrategia	ROC-AUC	PR-AUC	Brier	pend. cal.
E3 deslizando S=3	0.680	0.226	0.095	1.123
E2 expansiva	0.676	0.223	0.095	1.075
E3 deslizando S=2	0.676	0.222	0.095	1.053
E4 disparador	0.674	0.222	0.095	1.166
E3 deslizando S=5	0.679	0.219	0.095	1.039
E3 deslizando S=1	0.667	0.214	0.095	0.918
E1 estático	0.662	0.212	0.097	1.028

Cuadro 5: Comparación de estrategias de adaptación sobre bloques comunes (6–10). **E3 deslizando S = 3** obtiene el mejor PR-AUC promedio entre E1/E2/E3 y se elige como estrategia desplegada para la capa de decisión — coincide con la ventana de reentrenamiento de tamaño 3 propuesta originalmente en el plan de trabajo. E4 (disparador) se muestra por separado por ser condicional a los reentrenamientos que dispara (1 evento en el horizonte evaluado).

E3 deslizando S = 3 se elige como estrategia desplegada por su mejor PR-AUC promedio, coincidiendo con la ventana de reentrenamiento propuesta en el plan de trabajo.

7.4 Granularidad del monitoreo

Siguiendo la exploración pedida en el plan de trabajo (Fase 5), se repite el experimento E1 vs. E3 con $G \in \{5, 10, 15\}$ bloques: una granularidad más fina detecta el drift antes, a costa de ventanas más pequeñas y ruidosas. El reentrenamiento automático introduce un riesgo propio —degradar silenciosamente el modelo en producción— que el esquema HITL y el *shadow deployment* (Sección 11) mitigan.

8 Capa de Decisión y Caso de Negocio

El umbral óptimo de intervención se deriva de la matriz de costos: $p^* = C_i / (C_r \cdot e)$. Los pacientes se categorizan en Bajo/Moderado/Alto Riesgo, con cupo máximo de 15 % en Alto Riesgo por bloque para evitar fatiga de alertas [17].

Escenario	Modelo (3 cat.)	No interv.	Interv. a todos	Binario ($p \geq p^*$)	Ahorro vs. ref.
Base ($e = 0,18$)	\$1,797,592	\$1,822,600	\$2,044,532	\$1,807,089	\$25,008
Sensibilidad $e = 0,12$	\$1,806,584	\$1,822,600	\$2,153,888	\$1,819,168	\$16,016
$e = 0,18$	\$1,797,592	\$1,822,600	\$2,044,532	\$1,807,089	\$25,008
Sensibilidad $e = 0,38$	\$1,688,841	\$1,822,600	\$1,680,012	\$1,600,345	-\$8,829
Ocupación $> 85\%$	\$2,224,893	\$2,278,250	\$2,418,165	\$2,230,297	\$53,357

Cuadro 6: Costo esperado por cada 1,000 altas (US\$), promedio sobre bloques de decisión, bajo la estrategia adaptativa desplegada (t_1, t_2 : umbrales Bajo/Moderado y Moderado/Alto).

¿Vale la pena construir y mantener el monitoreo de drift, o basta con desplegar el modelo una vez? Se compara la política **sin monitoreo** (umbrales fijados en bloques 1–2) contra **con monitoreo** ($E3\ S = 3$), proyectada a escala anual [*Supuesto: 50,000 altas/año*] [16].

Concepto	Valor anual (US\$, 50,000 altas/año)
Costo esperado sin monitoreo (estático, umbral fijo)	\$90,268,164
Costo esperado con monitoreo adaptativo ($E3, S = 3$)	\$89,879,592
Ahorro bruto atribuible al monitoreo de drift	\$388,573
Costo de mantenimiento del sistema (monitoreo + reentrenos)	\$2,934
Beneficio neto	\$385,639
Retorno sobre la inversión (ROI)	132x

Cuadro 7: Caso de negocio anualizado (supuesto de escala: 50,000 altas/año).

El ahorro por cada 1,000 altas crece más de $16\times$ entre el bloque 4 (\$924) y el bloque 10 (\$15,114): el valor del monitoreo aumenta con el tiempo, pues un modelo sin vigilancia se degrada progresivamente. El costo de mantenimiento (monitoreo + cómputo + reentrenos) se construyó de abajo hacia arriba, no se asumió gratuito [13].

9 Auditoría de Equidad

Se audita la paridad del sistema por grupo etario (≥ 70 vs. < 70 años) y por **race**, evaluando solo grupos con al menos 100 reingresos observados.

Dimensión	Grupo	n	Reingresos	Tasa reingreso	Razón FNR	Cumple FNR
grupo_edad	<70	27,863	2,967	10.6 %	1.00	✓
grupo_edad	≥ 70	23,636	2,880	12.2 %	1.12	✓
race	AfricanAmerican	9,186	1,018	11.1 %	0.97	✓
race	Asian	375	31	8.3 %	—	n/e
race	Caucasian	38,999	4,514	11.6 %	1.00	✓
race	Desconocido	1,096	102	9.3 %	1.15	✓
race	Hispanic	1,012	98	9.7 %	—	n/e
race	Other	831	84	10.1 %	—	n/e

Cuadro 8: Auditoría de equidad por grupo etario y raza. “n/e” = no evaluable (< 100 reingresos). En la muestra evaluada, todos los grupos evaluables cumplen igualdad de oportunidad (razón de FNR). La razón de *selección* a Alto Riesgo entre subgrupos (regla del 80 %) sí incumple (mínimo observado ≈ 0.38) por el mecanismo de cupo global — ver discusión en la Sección de criterios no cumplidos.

El criterio de explicabilidad (top-3 factores SHAP, coincidentes con las variables monitoreadas por drift: insulina, diagnósticos, procedimientos y urgencias) se cumple en el 100 % de los casos, y la latencia ($p95 = 79.5$ ms) cumple ampliamente la restricción de 2 segundos (Sección 3).

10 Resultados Consolidados y Criterios No Cumplidos

Dimensión	Métrica	Criterio	Resultado	Cumple
Técnica	ROC-AUC	≥ 0.66	0.673 (peor 0.646)	✓
Técnica	PR-AUC / lift	≥ 0.20 y $\geq 1.8\times$	0.220 / $1.94\times$	✓
Técnica	Brier	≤ 0.095	0.0963 (BSS 0.044)	✗
Técnica	Pendiente de calibración	[0.85, 1.15]	1.05 (rango 0.78–1.44)	✓
Técnica	Intercepto de calibración	[-0.15, 0.15]	-0.031	✓
Técnica	ECE	≤ 0.02	0.0144	✓
Técnica	Latencia p95	$< 1,000$ ms	79.5 ms	✓
Decisión	Beneficio neto (DCA)	$\geq$ referencias en 0.05–0.30	supera en 100 % del rango	✓
Decisión	Costo esperado (base)	$<$ mín(referencias)	ahorro US\$25,008 / 1,000 altas	✓
Decisión	Costo esperado (sensibilidad e)	$<$ mín(referencias) para $e \in 0.12, 0.18, 0.38$	16,016 / 25,008 / -8,829	✗
Decisión	Impacto proyectado	$\geq 5\%$	3.8 %	✗
Decisión	Tasa de Alto por bloque	$\leq 15\%$	15.0 %	✓
Decisión	Tiempo de respuesta	$\geq 90\%$ contactados ≤ 7 días	N/A (despliegue)	—

Dimensión	Métrica	Criterio	Resultado	Cumple
Social	Razón FNR edad (≥ 70 vs < 70)	[0.87, 1.15]	≥ 70 : 1.12 [1.09–1.14]	✓
Social	Razón FNR raza (vs Caucasian)	[0.87, 1.15], ≥ 100 re-ingresos	AfricanAmerican: 0.97; Desconocido: 1.15	✓
Social	Razón de selección (80 %)	≥ 0.80	0.38	✗
Social	Calibración por subgrupo	pendiente [0.8, 1.2], $ \text{int.} \leq 0.2$	ver tabla de equidad	✓
Social	Cobertura	≥ 98 %	100.0 %	✓
Social	Incertidumbre Alta	≤ 15 %	37.6 %	✗
Social	Reingreso en categoría Bajo	< 8 %	6.5 %	✓
Social	Explicabilidad top-3	100 %	100.0 %	✓
Monitoreo	Reentrenamientos disparados (E4)	informativo	1	—
Monitoreo	Variables con PSI > 0.25 (vs B1)	informativo	admission_type_grp, num_lab_procedures, number_diagnoses_capped	—

Cuadro 9: Tabla resumen de criterios de aprobación, estrategia desplegada (E3, $S = 3$). 18 de 23 criterios cuantitativos se cumplen; los 5 restantes se discuten en el texto.

De los 23 criterios evaluados, 18 se cumplen. Los 5 restantes –Brier, costo esperado en el escenario de sensibilidad más optimista ($e = 0,38$), impacto proyectado, razón de selección (regla del 80 %) e incertidumbre alta– comparten causa de fondo: el techo de discriminación del modelo (ROC-AUC $\approx 0,67$), consistente con la literatura [7, 3]. La razón de selección es la única brecha estructural –el cupo global de Alto Riesgo no garantiza paridad entre subgrupos con tasas base distintas [1]– y se documenta como limitación bloqueante de despliegue (Sección 11).

11 Propuesta de Despliegue y Gestión de Riesgos

11.1 Propuesta de despliegue

Siguiendo el marco de opciones de despliegue visto en clase [15], se recomienda un despliegue por **microservicios en contenedor** (Docker) sobre **IaaS/PaaS** de nube –esta es la **arquitectura de implementación**–: el monitoreo de drift corre en *batch* y el módulo predictivo sirve inferencia síncrona (SLA < 2 s [9]), por lo que conviene escalarlos por separado, con reproducibilidad garantizada por MLflow.

El **flujo de datos** sigue el ciclo EHR $\rightarrow$ ingesta/validación $\rightarrow$ preprocesamiento $\rightarrow$ inferencia $\rightarrow$ acción clínica, con cómputo periódico de PSI/KS/ROC-AUC (Sección 7) que dispara el reentrenamiento (E4) con aprobación humana antes de reemplazar el modelo en producción (*shadow deployment*) y registro auditable. La **frecuencia de actualización** no sigue calendario fijo: es condicional a la degradación bloque a bloque, consistente con que la deuda técnica de un sistema de ML vive en el “glue code” alrededor del modelo [13]. La **autonomía** es parcial (HITL, Sección 3): recomienda, el médico decide. Escalar implica **desafíos de costos** (cómputo por sede) e **integración** (EHR heterogéneos; migrar `encounter_id` a fecha real).

11.2 Riesgos identificados

Riesgo	Descripción	Mitigación
Drift silencioso entre ciclos	Cambio abrupto degrada el modelo antes del siguiente chequeo.	Mayor frecuencia de monitoreo en periodos de alta variabilidad; alertas si PSI $> 0,25$.
Fatiga de alertas clínicas	Exceso de Alto Riesgo reduce la atención a cada alerta [17].	Cupo de 15 % por bloque; monitorear tasa de <i>override</i> .
Inequidad en la selección de Alto Riesgo	Razón de selección entre subgrupos por debajo de la regla del 80 %.	No desplegar sin resolver; evaluar cupos estratificados o post-procesamiento [6].
Fuga en cambios futuros / <code>encounter_id</code> como proxy temporal	Nuevas variables pueden reintroducir fugas (Sección 6); el proxy solo es válido para este dataset histórico.	Repetir la batería de 13 pruebas de <code>auditoria_leakage.csv</code> antes de integrar; migrar a fecha real de alta y revalidar embargo y ventanas.

12 Conclusiones

El sistema se diseñó, implementó y validó de punta a punta, cumpliendo el objetivo de mantener un desempeño confiable ante los cambios de los datos en el tiempo. La auditoría de fuga de información fue indispensable antes de confiar en las curvas de degradación reportadas. Las métricas cumplen la mayoría de los criterios *a priori*; las excepciones (Brier, razón de selección) tienen explicación en literatura y mitigación propuesta. El caso de negocio muestra que el monitoreo de drift se paga solo frente a su costo de mantenimiento, entregando un sistema validado y un valor económico cuantificado.

Bibliografía

Referencias

- [1] Chouldechova, A. (2017). Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. *Big Data*, 5(2), 153–163.
- [2] Drincic, A., Pfeffer, E., Luo, J., & Goldner, W. S. (2017). The effect of diabetes case management and Diabetes Resource Nurse program on readmissions of patients with diabetes mellitus. *Journal of Clinical & Translational Endocrinology*, 8, 29–34.
- [3] Emi-Johnson, O., & Nkrumah, K. (2025). Predicting hospital readmission risk with machine learning: benchmarks on the Diabetes 130-US hospitals dataset.
- [4] Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys*, 46(4), 1–37.
- [5] Ghabowen, I., et al. (2024). Cost of hospital readmissions attributable to diabetes.
- [6] Hardt, M., Price, E., & Srebro, N. (2016). Equality of opportunity in supervised learning. *Advances in Neural Information Processing Systems (NeurIPS)*, 29.
- [7] Kansagara, D., et al. (2011). Risk prediction models for hospital readmission: a systematic review. *JAMA*, 306(15), 1688–1698.
- [8] Leppin, A. L., et al. (2014). Preventing 30-day hospital readmissions: a systematic review and meta-analysis of randomized trials. *JAMA Internal Medicine*, 174(7), 1095–1107.
- [9] Nawaz. (2026). *How to instrument clinical decision support system response times*. OneUptime.
- [10] Platt, J. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. *Advances in Large Margin Classifiers*, 10(3), 61–74.
- [11] Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3).
- [12] Salim, & Ibrahim. (2026). Calibrated risk prediction for hospital readmission with nested cross-validation. *Research Square* (preprint).
- [13] Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems (NeurIPS)*, 28.
- [14] Siddiqi, N. (2006). *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. Wiley.
- [15] Soriano-Vargas, A. (2026). *Concept Drift* [Diapositivas de clase, Planificación y Toma de Decisiones en IA]. UTEC.
- [16] Strack, B., DeShazo, J. P., Gennings, C., Olmo, J. L., Ventura, S., Cios, K. J., & Clore, J. N. (2014). Impact of HbA1c measurement on hospital readmission rates: analysis of 70,000 clinical database patient records. *BioMed Research International*, 2014.
- [17] van der Sijs, H., et al. (2006). Overriding of drug safety alerts in computerized physician order entry. *Journal of the American Medical Informatics Association*, 13(2), 138–147.
- [18] van Walraven, C., Bennett, C., Jennings, A., Austin, P. C., & Forster, A. J. (2011). Proportion of hospital readmissions deemed avoidable: a systematic review. *Canadian Medical Association Journal*, 183(7), E391–E402.
- [19] Vickers, A. J., & Elkin, E. B. (2006). Decision curve analysis: a novel method for evaluating prediction models. *Medical Decision Making*, 26(6), 565–574.